

Aspect-Based Sentiment Analysis pada Ulasan Google Reviews Richeese Pizza Kota Bandung Menggunakan Fine-Tuning IndoBERT

Mochamad Rafly Taufik Putra Fadilah
Department of Information System
Universitas Komputer Indonesia
Bandung, Indonesia
rafly.10522022@mahasiswa.unikom.ac.id

Rayvanka Azrifany Nurviana Najmi
Department of Information System
Universitas Komputer Indonesia
Bandung, Indonesia
rayvanka.10522010@mahasiswa.unikom.ac.id

Niken Nuraifah Suherlan
Department of Information System
Universitas Komputer Indonesia
Bandung, Indonesia
niken.10522018@mahasiswa.unikom.ac.id

Aydil Harsy Putra
Department of Information System
Universitas Komputer Indonesia
Bandung, Indonesia
aydil.10522021@mahasiswa.unikom.ac.id

Abstract— Ulasan pelanggan pada platform daring seperti Google Reviews menjadi sumber informasi penting bagi pelaku usaha kuliner, namun analisis sentimen konvensional yang hanya menghasilkan satu label per ulasan belum mampu menggambarkan penilaian pelanggan terhadap aspek layanan secara spesifik. Penelitian ini menerapkan pendekatan *Aspect-Based Sentiment Analysis* (ABSA) pada ulasan Google Reviews tiga cabang Richeese Pizza di Kota Bandung untuk mengidentifikasi sentimen pelanggan terhadap lima aspek layanan, yaitu makanan, pelayanan, harga, fasilitas, dan suasana. Sebanyak 3.291 ulasan dikumpulkan menggunakan Google Maps Review Scraper dan diproses melalui tahapan *preprocessing* hingga menghasilkan 2.012 data bersih. Label sentimen diperoleh secara otomatis menggunakan model *pre-trained* RoBERTa berbahasa Indonesia, sedangkan label aspek diperoleh melalui pencocokan kata kunci berdasarkan kamus aspek yang disusun dengan bantuan *Large Language Model* (LLM). Dua model klasifikasi dibangun melalui *fine-tuning* IndoBERT dengan penanganan ketidakseimbangan kelas menggunakan *class weighting*, yaitu model sentimen (*single-label*, tiga kelas) dan model aspek (*multi-label*, lima kelas). Hasil pengujian menunjukkan model sentimen memperoleh akurasi 93,07% dan *macro* F1-score 80,80%, sedangkan model aspek memperoleh *macro* F1-score 90,63% dan *micro* F1-score 91,95%, dengan performa terbaik pada aspek pelayanan (F1-score 96,52%). Aspek makanan paling banyak dibahas pelanggan (34,0%), diikuti suasana (25,7%) dan pelayanan (25,3%), dengan mayoritas ulasan bersentimen positif (85,8%). Hasil ini diharapkan menjadi masukan bagi manajemen Richeese Pizza dalam menentukan prioritas perbaikan layanan.

Keywords— *aspect-based sentiment analysis, Google Reviews, IndoBERT, klasifikasi sentimen*

I. INTRODUCTION

Industri makanan dan minuman (F&B) di Indonesia berkembang pesat dan diiringi oleh persaingan yang semakin ketat antar pelaku usaha, termasuk pada segmen restoran cepat saji seperti pizza. Richeese Pizza merupakan salah satu merek yang terus memperluas jaringan gerainya di berbagai kota, termasuk Bandung, sehingga dituntut untuk terus menjaga kualitas produk dan layanan agar tetap kompetitif. Salah satu sumber informasi yang dapat dimanfaatkan untuk memahami persepsi pelanggan adalah ulasan daring (*online*

review) pada platform seperti Google Reviews, yang memuat opini pelanggan secara terbuka dan dapat diakses publik. Ulasan tersebut dapat dianalisis secara sistematis untuk menghasilkan wawasan (*insight*) yang bermanfaat bagi pengambilan keputusan bisnis [1].

Meningkatnya jumlah ulasan pelanggan membuat proses pembacaan dan interpretasi secara manual menjadi tidak efisien, sehingga dibutuhkan pendekatan otomatis berbasis *Natural Language Processing* (NLP) untuk mengekstraksi informasi dari data tersebut. Analisis sentimen konvensional pada umumnya hanya menghasilkan satu label sentimen (positif, negatif, atau netral) untuk keseluruhan ulasan, padahal dalam praktiknya satu ulasan sering membahas beberapa aspek layanan sekaligus dengan sentimen yang berbeda-beda, misalnya pelanggan yang memuji rasa makanan namun mengeluhkan kecepatan pelayanan [2][3]. Keterbatasan ini membuat hasil analisis sentimen konvensional kurang informatif untuk mendukung evaluasi bisnis yang lebih terarah. *Aspect-Based Sentiment Analysis* (ABSA) dikembangkan untuk mengatasi keterbatasan tersebut dengan mengidentifikasi aspek spesifik yang dibahas dalam sebuah ulasan beserta sentimen terhadap masing-masing aspek, sehingga menghasilkan wawasan yang lebih granular dan *actionable* bagi pelaku usaha [4].

Pendekatan ABSA telah banyak diterapkan pada berbagai jenis ulasan berbahasa Indonesia dengan memanfaatkan model transformer seperti IndoBERT. Pada ulasan Google Review restoran Sunda di Bogor, ABSA diterapkan menggunakan *fine-tuning* IndoBERT untuk mengidentifikasi sentimen pelanggan terhadap aspek makanan, pelayanan, harga, suasana, dan fasilitas [5]. Pendekatan serupa turut diterapkan pada ulasan Google Maps kawasan wisata Taman Nasional Bromo Tengger Semeru [6], ulasan hotel bintang lima Jakarta [7], serta ulasan produk songket sebagai salah satu UMKM tradisional [8], yang secara konsisten menunjukkan bahwa IndoBERT mampu memberikan performa tinggi dalam mengidentifikasi sentimen pada level aspek. Selain pada ulasan produk dan layanan, pendekatan ABSA berbasis BERT juga telah divalidasi secara lebih luas pada umpan balik mahasiswa di Indonesia, menegaskan konsistensi performanya lintas domain [9]. Meskipun

demikian, sebagian besar penelitian tersebut berfokus pada satu lokasi atau satu merek usaha, sehingga penerapan ABSA pada bisnis waralaba dengan banyak cabang sekaligus, seperti restoran cepat saji, masih relatif jarang dieksplorasi.

Selain pendekatan berbasis model bahasa besar, algoritma pembelajaran mesin konvensional seperti *Support Vector Machine* (SVM) juga terbukti efektif digunakan pada klasifikasi sentimen ulasan restoran berbahasa Indonesia. Penerapan SVM pada ulasan restoran menghasilkan akurasi dan F1-score sebesar 93% [10]. Studi lain yang membandingkan SVM dengan *k-Nearest Neighbor* (k-NN) pada ulasan pengguna restoran menunjukkan bahwa SVM memberikan performa yang lebih baik dengan akurasi 81,92% [11]. Perbandingan serupa antara SVM dan *Naïve Bayes Classifier* pada ulasan rumah makan Ayam Goreng Nelongso di Malang turut menunjukkan keunggulan SVM, dengan akurasi masing-masing sebesar 92,74% dan 91,67% [12]. Pada konteks ABSA secara khusus, SVM juga telah digunakan untuk tahap kategorisasi aspek pada ulasan restoran berbahasa Indonesia [13]. Namun, pendekatan-pendekatan tersebut sebagian besar masih diterapkan pada klasifikasi sentimen konvensional atau kategorisasi aspek secara terpisah, belum mengintegrasikan klasifikasi sentimen dan aspek secara bersamaan dalam satu kerangka ABSA berbasis *deep learning*.

Berdasarkan tinjauan tersebut, terdapat kesenjangan (*gap*) penelitian yang dapat diidentifikasi. Selain keterbatasan cakupan lokasi seperti diuraikan sebelumnya, penerapan ABSA berbasis IndoBERT pada umumnya juga membutuhkan proses pelabelan data secara manual untuk kebutuhan pelatihan model, baik pada level sentimen maupun aspek, yang membutuhkan waktu dan tenaga yang tidak sedikit. Di sisi lain, algoritma pembelajaran mesin konvensional seperti SVM cenderung lebih ringan secara komputasi, namun sebagian besar penerapannya masih terbatas pada klasifikasi sentimen konvensional tanpa mempertimbangkan aspek layanan secara spesifik. Penelitian ini berupaya menjembatani kesenjangan-kesenjangan tersebut dengan memanfaatkan model *pre-trained* berbasis transformer untuk pelabelan sentimen secara otomatis, pencocokan kata kunci berbasis kamus aspek yang disusun dengan bantuan *Large Language Model* (LLM) untuk pelabelan aspek, serta *fine-tuning* IndoBERT sebagai model klasifikasi akhir untuk kedua tugas tersebut secara terpisah, yang diterapkan sekaligus pada data ulasan dari tiga cabang restoran cepat saji.

Berdasarkan uraian tersebut, penelitian ini bertujuan untuk membangun sistem *Aspect-Based Sentiment Analysis* pada ulasan Google Reviews Richeese Pizza di tiga cabang Kota Bandung, yaitu Riau, Buahbatu, dan Dago. Sistem yang dibangun mengklasifikasikan sentimen pelanggan (positif, netral, negatif) terhadap lima aspek layanan, yaitu makanan, pelayanan, harga, fasilitas, dan suasana. Label sentimen diperoleh secara otomatis menggunakan model *pre-trained* berbasis RoBERTa berbahasa Indonesia, sedangkan label aspek diperoleh melalui pencocokan kata kunci berdasarkan kamus aspek yang disusun dengan bantuan *Large Language Model* (LLM) sebagai asisten anotasi teks, mengingat penelitian terdahulu menunjukkan bahwa LLM mampu memberikan hasil anotasi teks yang kompetitif dibandingkan anotator manusia [14]. Data yang telah diberi label kemudian digunakan untuk melatih dua model klasifikasi terpisah melalui *fine-tuning* IndoBERT, yaitu model klasifikasi

sentimen (*single-label*, tiga kelas) dan model klasifikasi aspek (*multi-label*, lima kelas), dengan penanganan ketidakseimbangan kelas menggunakan pendekatan *class weighting*. Hasil penelitian ini diharapkan dapat memberikan gambaran mengenai aspek layanan yang paling sering dibahas serta sentimen pelanggan terhadap masing-masing aspek tersebut, sehingga dapat menjadi dasar evaluasi dan penentuan prioritas perbaikan layanan bagi manajemen Richeese Pizza.

II. METHODOLOGY

Penelitian ini dilaksanakan melalui beberapa tahapan, yang dapat dilihat pada Fig. 1. Dimulai dari pengumpulan data hingga evaluasi hasil.




Fig. 1. Methodology

A. Data Collecting

Data yang digunakan dalam penelitian ini berupa ulasan pelanggan yang diperoleh dari Google Reviews Richeese Pizza. Proses pengumpulan data dilakukan menggunakan Google Maps Reviews Scraper yang tersedia di Apify [1]. Pengambilan data dilakukan pada tiga cabang Richeese Pizza di Kota Bandung, yaitu cabang Riau, Buahbatu, dan Dago. Proses scraping dilaksanakan pada tanggal 19 Mei 2026. Data yang dikumpulkan meliputi informasi cabang serta ulasan pelanggan yang diberikan pada masing-masing cabang. Seluruh data yang diperoleh kemudian digunakan sebagai dataset dalam proses analisis sentimen berbasis aspek pada penelitian ini.

B. Sentiment Labelling

Pelabelan sentimen dilakukan secara otomatis menggunakan model *pre-trained* w11wo/indonesian-roberta-base-sentiment-classifier yang dibangun berdasarkan arsitektur RoBERTa dan diadaptasi untuk pemrosesan teks berbahasa Indonesia [15]. Model tersebut mengklasifikasikan setiap ulasan ke dalam salah satu dari tiga kategori sentimen, yaitu *positive*, *neutral*, atau *negative* (*single-label classification*). Proses pelabelan dilakukan pada data mentah (*raw data*) sebelum tahap *preprocessing* untuk mempertahankan konteks linguistik sehingga informasi yang digunakan dalam proses klasifikasi tetap representatif.

C. Data Preprocessing

Data preprocessing merupakan tahapan awal dalam *Natural Language Processing* (NLP) yang bertujuan untuk membersihkan, menormalkan, dan menyeragamkan data teks agar siap digunakan pada proses analisis maupun pelatihan model. Tahap ini berperan penting dalam mengurangi *noise* pada data sehingga dapat meningkatkan kualitas data masukan dan mendukung kinerja model secara keseluruhan [16]. Pada penelitian ini, *preprocessing* meliputi *data cleaning*, *case*

folding, tokenizing, stemming, slang normalization, dan stopword removal.

1) Data Cleaning.

Data cleaning dilakukan untuk menghilangkan data yang dapat memengaruhi kualitas analisis. Tahap ini meliputi penghapusan baris yang memiliki nilai missing value pada kolom ulasan, penghapusan data duplikat, serta pembersihan teks menggunakan regular expression. Proses pembersihan mencakup penghapusan tautan (URL), angka, karakter selain huruf dan angka, penggantian karakter baris baru (newline) menjadi spasi, serta penghapusan spasi berlebih pada awal dan akhir teks.

2) Case Folding

Case folding merupakan proses mengubah seluruh karakter pada teks menjadi huruf kecil (*lowercase*) untuk menyeragamkan format penulisan kata sehingga konsisten pada tahap analisis selanjutnya.

3) Slang Normalization

Slang normalization dilakukan dengan mengonversi kata tidak baku, singkatan, dan bahasa gaul menjadi bentuk baku menggunakan kamus normalisasi yang merupakan gabungan dari KBBA, Kamus Alay, serta kamus kustom yang disusun pada penelitian ini.

4) Tokenizing

Tokenizing merupakan proses memecah teks menjadi unit-unit kata (*token*) sehingga setiap ulasan direpresentasikan dalam bentuk kumpulan token yang siap diproses pada tahapan *preprocessing* berikutnya.

5) Stopword Removal

Stopword removal dilakukan dengan menghapus kata-kata umum menggunakan daftar stopwords bahasa Indonesia dan bahasa Inggris serta daftar stopwords tambahan yang disusun pada penelitian ini, dengan tetap mempertahankan kata-kata penting yang berkaitan dengan aspek layanan.

D. Aspect Labelling

Pelabelan aspek dilakukan menggunakan pendekatan *keyword matching* berdasarkan *aspect dictionary* yang dibangun sebelumnya. *Aspect dictionary* dikembangkan dengan bantuan *Large Language Model* (LLM), yaitu Claude AI, sebagai *text annotation assistant* untuk mengidentifikasi kata kunci yang merepresentasikan setiap kategori aspek. Penggunaan LLM dalam proses anotasi bertujuan meningkatkan efisiensi serta konsistensi dalam penyusunan *aspect dictionary*, sebagaimana telah diterapkan pada penelitian sebelumnya [14].

Kategori aspek yang digunakan dalam penelitian ini meliputi aspek makanan, pelayanan, harga, suasana, fasilitas [5]. Proses pelabelan menerapkan pendekatan *multi-label classification*, sehingga satu ulasan dapat dikaitkan dengan lebih dari satu aspek apabila mengandung beberapa kata kunci yang sesuai dengan *aspect dictionary*.

E. Split Data

Split Data dilakukan terhadap dataset yang telah melalui proses pelabelan dan *preprocessing*. Dataset dibagi menjadi data latih, data validasi, dan data uji dengan rasio 80:10:10. Untuk klasifikasi sentimen, pembagian data dilakukan menggunakan pendekatan *stratified sampling* agar proporsi masing-masing kelas sentimen pada data latih, validasi, dan uji tetap identik dengan distribusi pada dataset keseluruhan. Pendekatan ini penting mengingat distribusi sentimen pada

dataset tidak seimbang, sehingga tanpa stratifikasi terdapat risiko kelas minoritas tidak terwakili secara proposional pada salah satu subset data, yang dapat menyebabkan evaluasi model menjadi bias [17]. Sementara itu, untuk klasifikasi aspek yang bersifat multi-label, pembagian data dilakukan secara acak dengan *random state* tetap, mengingat kombinasi label pada data multi-label terlalu beragam untuk distratifikasi secara sempurna.

F. Data Transformation

Tahap transformasi data bertujuan untuk mengonversi data hasil pelabelan ke dalam format numerik yang dapat diproses oleh model. Pada label sentimen, dilakukan *label encoding* untuk mengonversi tiga kategori sentimen, yaitu positif, netral, negatif, menjadi representasi numerik tunggal (0,1,2). Pada label aspek yang bersifat multi-label, dilakukan proses *binarization* menggunakan pendekatan *MultiLabelBinarizer*, sehingga setiap ulasan direpresentasikan sebagai vektor multi-hot yang menunjukkan aktif atau tidaknya setiap kategori aspek secara independen. Untuk data teks, transformasi dilakukan melalui proses tokenisasi menggunakan tokenizer IndoBERT berbasis *WordPiece*, yang mengonversi teks menjadi *input ids* dan *attention mask* dengan panjang token yang diseragamkan. Fitur teks yang digunakan sebagai masukan model adalah hasil *slang normalization* tanpa proses *stemming* dan *stopword removal* lanjutan, karena arsitektur *transformer* seperti IndoBERT memanfaatkan mekanisme *self-attention* yang bergantung pada struktur kalimat yang utuh untuk memahami kontekstual yang relevan bagi model [17].

G. Imbalance Handling

Penanganan ketidakseimbangan data dilakukan dengan pendekatan *class weighting* yang diintegrasikan ke dalam fungsi *loss* pada tahap pelatihan model, diterapkan secara terpisah untuk kedua klasifikasi. Pada klasifikasi sentimen, bobot kelas dihitung dari data latih menggunakan skema *balanced*, yaitu bobot yang berbanding terbalik dengan frekuensi kemunculan tiap kelas sentimen, sehingga kelas dengan jumlah sampel lebih sedikit memperoleh bobot yang lebih besar dibandingkan kelas mayoritas. Bobot tersebut kemudian dimasukkan sebagai parameter pada fungsi *Cross Entropy Loss*, sehingga kesalahan prediksi pada kelas minoritas memberikan kontribusi *loss* yang lebih besar terhadap proses pembaruan bobot model [18]. Pada task klasifikasi aspek yang bersifat multi-label, penanganan ketidakseimbangan dilakukan melalui parameter *pos weight*, yaitu rasio antara jumlah sampel negatif terhadap jumlah sampel positif yang dihitung secara independen untuk masing-masing dari lima kategori aspek pada data latih. Nilai *pos weight* tersebut kemudian diterapkan pada fungsi *Binary Cross Entropy with Logits Loss* yang digunakan selama pelatihan model klasifikasi aspek [19]. Perhitungan bobot pada kedua task dilakukan hanya berdasarkan data latih, dengan tujuan menjaga agar data validasi dan data uji tetap merepresentasikan distribusi data asli secara utuh tanpa intervensi.

H. Modelling

Proses pemodelan dilakukan melalui *fine-tuning* terhadap model *pre-trained* IndoBERT, yang telah dilatih sebelumnya pada korpus besar berbahasa Indonesia dan terbukti efektif untuk berbagai tugas *Aspect-Based Sentiment Analysis* pada domain ulasan pelanggan berbahasa Indonesia [20] [7]. Penelitian ini membangun dua model klasifikasi terpisah yang

masing-masing menangani satu subtugas, Model pertama menangani klasifikasi sentimen sebagai *single-label classification* dengan tiga kelas keluaran. Model kedua menangani klasifikasi aspek sebagai *multi-label classification* dengan lima kelas keluaran yang saling independen, menggunakan fungsi aktivasi *sigmoid* pada tiap neuron keluaran sehingga satu ulasan dapat memiliki lebih dari satu aspek aktif secara bersamaan berdasarkan ambang batas 0,5 [19]. Kedua model dilatih menggunakan *optimizer* AdamW dengan skema pembelajaran berbasis *epoch*, dimana performa pada data validasi dipantau di setiap akhir *epoch* untuk memilih bobot model dengan performa terbaik, guna mencegah *overfitting* selama proses *fine-tuning* [17].

I. Evaluation

Evaluasi kinerja model dilakukan secara terpisah untuk masing-masing klasifikasi, mengingat karakteristik keduanya yang berbeda. Untuk model klasifikasi sentimen, evaluasi menggunakan metrik akurasi, presisi, *recall*, dan *F1-score* per kelas, serta *macro average F1-score* sebagai metrik utama. Penggunaan *macro F1-score* lebih diutamakan dibandingkan akurasi mengingat distribusi data yang tidak seimbang, karena akurasi cenderung memberikan gambaran kinerja yang kurang sesuai apabila model hanya unggul memprediksi kelas mayoritas [17]. *Confusion matrix* turut digunakan untuk memvisualisasikan pola kesalahan klasifikasi antar kelas sentimen secara lebih rinci. Untuk model klasifikasi aspek yang bersifat multi label, evaluasi menggunakan kombinasi metrik yang lebih sesuai dengan karakteristik multi label, yaitu *micro F1-score* dan *macro F1-score* untuk mengukur kinerja keseluruhan maupun kinerja rata-rata per label, *Hamming Loss* untuk mengukur proporsi kesalahan prediksi label secara keseluruhan, serta *subset accuracy* sebagai metrik paling ketat yang mensyaratkan seluruh kombinasi label pada satu ulasan diprediksi secara tepat [19]. *Confusion matrix* juga dibangun secara terpisah untuk setiap label aspek guna menganalisis pola kesalahan prediksi pada masing-masing kategori aspek secara individual.

III. RESULT

Hasil penelitian disajikan secara sistematis berdasarkan tahapan penelitian yang telah dilakukan. Setiap hasil dianalisis dan didukung oleh tabel serta gambar untuk mempermudah interpretasi.

A. Data Collecting

Proses pengumpulan data menghasilkan sebanyak 3.291 ulasan pelanggan yang diperoleh dari tiga cabang Richeese Pizza di Kota Bandung, yaitu cabang Riau, Buahbatu, dan Dago. Data yang dikumpulkan meliputi informasi cabang serta ulasan pelanggan pada masing-masing cabang. Setelah dilakukan proses data cleaning dengan menghapus data yang memiliki *missing value* dan data duplikat, diperoleh sebanyak 2.012 data bersih yang selanjutnya digunakan pada tahapan penelitian berikutnya.

TABLE I. HASIL PENGUMPULAN DATA

Cabang	Ulasan
Dago	pizzanya enak, penasaran coba menu lain
Dago	makanan enak pelayanan oke
Dago	Menarik mas nya ramah pizza enak
...	...

Cabang	Ulasan
Riau	pizza aloha shrimp nyaa enak pelayanannya sigap dan ambiencenya nyamann
Riau	Good service

B. Sentiment Labelling

Proses pelabelan sentimen dilakukan secara otomatis menggunakan model *pre-trained* w11wo/indonesian-roberta-base-sentiment-classifier terhadap seluruh data hasil *data cleaning*. Setiap ulasan diklasifikasikan ke dalam salah satu dari tiga kategori sentimen, yaitu *positive*, *neutral*, atau *negative*. Jumlah data pada masing-masing kategori disajikan pada Tabel II.

TABLE II. HASIL PENGUMPULAN DATA

Label Sentimen	Jumlah	Presentasi
Positive	1.726	85,8%
Neutral	250	12,4%
Negative	36	1,8%
Total	2.012	100%

Hasil pelabelan sentimen menghasilkan distribusi kelas sebagaimana ditunjukkan pada TABLE II. sebagian besar ulasan diklasifikasikan ke dalam kategori *positive* sebanyak 1.726 ulasan (85,8%), diikuti oleh kategori *negative* sebanyak 250 ulasan (12,4%) dan kategori *neutral* sebanyak 36 ulasan (1,8%).

Distribusi jumlah ulasan pada setiap kategori sentimen divisualisasikan pada Fig. 2. Terlihat bahwa jumlah ulasan dengan sentimen *positive* jauh lebih tinggi dibandingkan kategori lainnya sehingga menunjukkan adanya ketidakseimbangan distribusi kelas.




Fig. 2. Distribusi Hasil Labelling Sentimen

Distribusi tersebut menunjukkan bahwa dataset memiliki ketidakseimbangan kelas (*class imbalance*), terutama pada kategori *neutral* yang memiliki jumlah data paling sedikit. Kondisi ini menjadi dasar penerapan teknik *imbalance handling* pada tahapan penelitian selanjutnya. Hasil labelling sentimen dapat dilihat seperti pada TABLE III.

TABLE III. HASIL LABELLING SENTIMENT

Ulasan	Sentiment Label
pizzanya enak, penasaran coba menu lain	positive

Ulasan	Sentiment Label
Untuk ayamnya kurang berbumbu seperti di cabang lain, fasilitas biasa standar	negative
Banyak promo	neutral

C. Data Preprocessing

Proses *data preprocessing* diterapkan secara bertahap untuk meningkatkan kualitas data sebelum memasuki tahap pemodelan. Setiap tahapan menghasilkan perubahan pada bentuk teks yang bertujuan mengurangi *noise* dan menyeragamkan representasi data.

1) Data Cleaning.

Tahap data cleaning berhasil menghilangkan data yang mengandung missing value, data duplikat, serta karakter yang tidak relevan pada teks ulasan. Selain itu, proses pembersihan menggunakan regular expression menghapus tautan (URL), angka, karakter khusus, karakter newline, dan spasi berlebih sehingga menghasilkan teks yang lebih bersih. Contoh hasil data cleaning ditunjukkan pada TABLE III.

TABLE IV. HASIL DATA CLEANING

Ulasan	Ulasan Setelah Cleaning
pizzanya enak, penasaran coba menu lain	pizza nya enak penasaran coba menu lain
makanan enak pelayanan oke	makanan enak pelayanan oke
Menarik mas nya ramah pizza enak	Menarik mas nya ramah pizza enak

2) Case Folding

Setelah proses *data cleaning*, seluruh teks dikonversi menjadi huruf kecil (*lowercase*) untuk menyeragamkan format penulisan. Hasil *case folding* menghasilkan representasi teks yang lebih konsisten sehingga meminimalkan perbedaan akibat penggunaan huruf kapital. Contoh hasil proses ini ditunjukkan pada Tabel X.

TABLE V. HASIL CASE FOLDING

Ulasan Setelah Cleaning	Ulasan Setelah Case Folding
pizza nya enak penasaran coba menu lain	pizza nya enak penasaran coba menu lain
makanan enak pelayanan oke	makanan enak pelayanan oke
Menarik mas nya ramah pizza enak	menarik mas nya ramah pizza enak

3) Slang Normalization

Tahap slang normalization berhasil mengubah kata tidak baku, singkatan, dan bahasa gaul menjadi bentuk baku menggunakan kamus normalisasi yang merupakan gabungan dari KBBA, Kamus Alay, serta kamus kustom. Proses ini meningkatkan konsistensi kosakata sehingga teks menjadi lebih mudah dipahami pada tahap analisis berikutnya. Hasil normalisasi ditunjukkan pada TABLE VI.

TABLE VI. HASIL SLANG NORMALIZATION

Ulasan Setelah Case Folding	Ulasan Setelah Slang Normalization
Enakk kejunya banyak pink lava manis tempat sepi adem	enak keju nya banyak pink lava manis tempat sepi sejuk
okee banget	oke banget
LEZATTTTT POL BAGI PENYUKA KEJU ❤️	lezat sekali bagi penyuka keju

4) Tokenizing

Tahap *tokenizing* mengubah setiap ulasan menjadi kumpulan token berupa kata-kata penyusun kalimat. Representasi ini memudahkan proses pengolahan teks pada tahapan selanjutnya. Hasil *tokenizing* ditunjukkan pada TABLE VII.

TABLE VII. HASIL TOKENIZING

Ulasan Setelah Slang Normalization	Tokenizing
pizza nya enak penasaran coba menu lain	['pizza', 'nya', 'enak', 'penasaran', 'coba', 'menu', 'lain']
makanan enak pelayanan oke	['makanan', 'enak', 'pelayanan', 'oke']
menarik mas nya ramah pizza enak	['menarik', 'mas', 'nya', 'ramah', 'pizza', 'enak']

5) Stopword Removal

Proses *stopword removal* berhasil menghilangkan kata-kata umum yang tidak memiliki kontribusi signifikan terhadap makna utama kalimat. Dengan demikian, teks menjadi lebih ringkas dan hanya mempertahankan kata-kata yang bersifat informatif. Contoh hasil proses ini ditunjukkan pada TABLE VIII.

TABLE VIII. HASIL STOPWORD REMOVAL

Tokenizing	Stopword Removal
['pizza', 'nya', 'enak', 'penasaran', 'coba', 'menu', 'lain']	['pizza', 'nya', 'enak', 'penasaran', 'coba', 'menu']
['makanan', 'enak', 'pelayanan', 'oke']	['makanan', 'enak', 'pelayanan', 'oke']
['menarik', 'mas', 'nya', 'ramah', 'pizza', 'enak']	['menarik', 'mas', 'nya', 'ramah', 'pizza', 'enak']

Setelah proses *stopword removal*, kumpulan token direkonstruksi menjadi bentuk kalimat utuh sehingga lebih mudah diinterpretasikan. Hasil rekonstruksi kalimat ditampilkan pada Tabel IX.

TABLE IX. HASIL REKONSTRUKSI KALIMAT

Stopword Removal	Teks Setelah Preprocessing
['pizza', 'nya', 'enak', 'penasaran', 'coba', 'menu']	pizza nya enak penasaran coba menu
['makanan', 'enak', 'pelayanan', 'oke']	makan enak layan oke
['menarik', 'mas', 'nya', 'ramah', 'pizza', 'enak']	tarik mas nya ramah pizza enak

D. Aspect Labelling

Sebagai dasar pelabelan aspek, disusun *aspect dictionary* yang memuat kata kunci untuk setiap kategori aspek. Kamus tersebut digunakan dalam proses *keyword matching* untuk mengklasifikasikan ulasan ke dalam lima aspek, yaitu makanan, pelayanan, harga, suasana, dan fasilitas. *Aspect dictionary* yang digunakan disajikan pada Tabel X.

TABLE X. ASPECT DICTIONARY

Aspek	Keywords
makanan	['pizza', 'enak', 'lezat', ..., 'yummy', 'maknyus']

Aspek	Keywords
pelayanan	['layan', 'pelayanan', 'service', ..., 'kakak', 'teteht']
harga	['harga', 'price', 'murah', ..., 'ekonomi', 'harga pas']
suasana	['suasana', 'ambience', 'ambiance', ..., 'keluarga', 'strategis']
fasilitas	['parkir', 'tempat parkir', 'lahan parkir', ..., 'dummy pizza', 'display']

Proses pelabelan aspek mengklasifikasikan ulasan ke dalam lima kategori aspek berdasarkan *aspect dictionary* yang telah disusun, dengan menggunakan pendekatan *multi-label classification*, dimana satu ulasan dapat dikaitkan dengan lebih dari satu aspek apabila mengandung beberapa kata kunci yang sesuai. Hasil pelabelan aspek ditunjukkan seperti pada TABLE XI.

TABLE XI. HASIL PELABELAN ASPEK

Ulasan	Sentiment Label	Aspect Label
pizzanya enak, penasaran coba menu lain	positive	['makanan']
tempat nya bersih pelayanan nya baik dam suasana nya nyaman	negative	['pelayanan', 'suasana', 'fasilitas']
Banyak promo	neutral	['harga']

Distribusi hasil pelabelan aspek ditunjukkan pada Tabel XII.

TABLE XII. HASIL PENGUMPULAN DATA

Label Sentimen	Jumlah	Presentasi
Makanan	1.496	34,0%
Suasana	1.129	25,7%
Pelayanan	1.113	25,3%
Fasilitas	421	9,6%
Harga	233	5,3%

Berdasarkan Tabel XII, aspek makanan merupakan aspek yang paling banyak muncul dengan 1.496 kemunculan (34,0%), diikuti oleh aspek suasana sebanyak 1.129 kemunculan (25,7%) dan aspek pelayanan sebanyak 1.113 kemunculan (25,3%). Sementara itu, aspek fasilitas dan harga memiliki frekuensi kemunculan yang lebih rendah, masing-masing sebesar 421 (9,6%) dan 233 (5,3%). Distribusi jumlah kemunculan setiap aspek divisualisasikan pada Fig. 3.




Fig. 3. Distribusi Aspek

Terlihat bahwa ulasan pelanggan lebih banyak membahas aspek makanan, suasana, dan pelayanan dibandingkan aspek lainnya. Hal ini menunjukkan bahwa ketiga aspek tersebut menjadi fokus utama pelanggan dalam memberikan ulasan terhadap Richeese Pizza.

E. Split Data

Pada tahap ini, dataset yang telah melalui proses pelabelan sentimen dan aspek dibagi menjadi data latih, data validasi, dan data uji dengan rasio 80:10:10. Pembagian data untuk klasifikasi sentimen dilakukan menggunakan pendekatan *stratified sampling* berdasarkan label sentimen, sehingga proporsi masing-masing kelas pada data latih, validasi, dan uji tetap sebanding dengan distribusi pada dataset keseluruhan. Hasil pembagian menghasilkan 1.608 data latih, 201 data validasi, dan 202 data uji. Distribusi kelas pada data latih menunjukkan sebanyak 199 ulasan berlabel negatif, 29 ulasan berlabel *neutral*, dan 1.380 ulasan berlabel positif.

Sementara itu, pembagian data untuk task klasifikasi aspek dilakukan secara acak dengan proporsi yang sama, yaitu 80:10:10, menghasilkan 1.608 data latih, 201 data validasi, dan 202 data uji. Berbeda dengan sentimen, stratifikasi langsung tidak diterapkan pada aspek, mengingat sifat label aspek yang multi label, sehingga kombinasi antar label yang mungkin muncul terlalu beragam untuk dapat distratifikasi secara sempurna. Proporsi kemunculan tiap label aspek pada data latih diverifikasi setelah proses pembagian data dilakukan. Hasil verifikasi menunjukkan proporsi kemunculan label pada data latih yang ditunjukkan TABLE XIII.

TABLE XIII. HASIL SPLIT DATA

Label Aspek	Proporsi Data Latih
Makanan	74,3%
Suasana	55,8%
Pelayanan	55,3%
Fasilitas	21,2%
Harga	11,6%

F. Data Transformation

Tahap transformasi data bertujuan mengubah hasil pelabelan menjadi representasi numerik yang dapat diproses oleh model IndoBERT. Label sentimen dikonversi menggunakan LabelEncoder, sehingga kategori negatif, neutral, dan positif direpresentasikan sebagai 0, 1, dan 2 seperti pada TABLE XIV.

TABLE XIV. HASIL DATA TRANSFORMATION

Label Sentimen	Indeks Vektor
Negatif	0
Netral	1
Positif	2

Label aspek bersifat multi label dikonversi menggunakan MultiLabelBinarizer menjadi vektor *multi-hot* berdimensi lima sesuai jumlah kategori aspek. Setiap elemen vektor bernilai 1 jika aspek terkait muncul pada ulasan dan 0 jika tidak. Tahap berikutnya adalah tokenisasi menggunakan tokenizer IndoBERT berbasis WordPiece. Setiap ulasan

dikonversi menjadi *input IDs* dan *attention mask* dengan panjang yang diseragamkan melalui proses *padding* dan *truncation* berdasarkan nilai *MAX_LEN*. Seluruh data kemudian dibungkus dalam kelas dataset sehingga siap digunakan pada proses pelatihan, validasi, dan pengujian model.

G. Imbalance Handling

Penanganan ketidakseimbangan data dilakukan melalui *class weighting* yang diterapkan pada fungsi *loss*, dihitung dari data latih. Untuk task sentimen, bobot dihitung menggunakan skema *balanced*, menghasilkan bobot 2,693 untuk kelas *negative*, 18,483 untuk *neutral*, dan 0,388 untuk *positive*. Bobot tersebut diterapkan pada fungsi *Cross Entropy Loss*, sehingga kesalahan prediksi pada kelas *neutral* diberi penalti jauh lebih besar dibandingkan kelas *positive*.

TABLE XV. HASIL PEMBOBOTAN KELAS SENTIMEN

Label Sentimen	Bobot Kelas
Negatif	2,693
Netral	18,483
Positif	0,388

Untuk task aspek yang bersifat multi-label, digunakan parameter *pos_weight*, yaitu rasio jumlah sampel negatif terhadap positif pada tiap label. Hasil perhitungan menunjukkan nilai tertinggi pada aspek harga (7,645) dan fasilitas (3,716), sejalan dengan rendahnya proporsi kemunculan kedua aspek tersebut pada data latih. Nilai *pos_weight* ini diterapkan pada fungsi *Binary Cross Entropy with Logits Loss*, sehingga model diberi penalti lebih besar saat gagal mengenali aspek yang jarang muncul.

TABLE XVI. HASIL PEMBOBOTAN KELAS ASPEK

Label Sentimen	Pos_weight
Fasilitas	3,716
Harga	7,645
Makanan	0,347
Pelayanan	0,807
Suasana	0,793

H. Modelling

Model sentimen dilatih menggunakan *Cross Entropy Loss* yang dimodifikasi dengan bobot kelas hasil perhitungan pada TABLE XVII. Progress pelatihan menunjukkan peningkatan *macro F1-score* validasi dari 0,6228 pada *epoch* pertama hingga mencapai nilai tertinggi 0,8015 pada *epoch* ke 3, sebelum sedikit menurun pada *epoch* ke 4 akibat *validation loss* yang mulai meningkat sebagai indikasi *overfitting*. Berdasarkan kriteria *macro F1-score* validasi tertinggi, bobot model dari *epoch* ke 3 dipilih sebagai model akhir.

TABLE XVII. HASIL PEMODELAN SENTIMEN

Epoch	Training Loss	Validation Loss	Accuracy	Macro F1
1	0,9231	0,5669	0,8905	0,6228
2	0,4140	0,4731	0,8955	0,7552
3	0,2593	0,6001	0,9104	0,8015
4	0,1632	0,7189	0,8955	0,7950

Model aspek dilatih menggunakan *Binary Cross Entropy with Logits Loss* yang dimodifikasi dengan *pos_weight* hasil perhitungan pada TABLE XVIII. Progres pelatihan menunjukkan peningkatan *macro F1-score* validasi secara konsisten di setiap *epoch*, dari 0,8160 pada *epoch* pertama hingga mencapai 0,9221 pada *epoch* ke-4, diiringi penurunan *validation loss* yang stabil tanpa indikasi *overfitting*. Berdasarkan kriteria yang sama, bobot model dari *epoch* ke-4 dipilih sebagai model akhir.

TABLE XVIII. HASIL PEMODELAN ASPEK

Epoch	Training Loss	Validation Loss	Accuracy	Macro F1
1	0,9231	0,5669	0,8905	0,6228
2	0,4140	0,4731	0,8955	0,7552
3	0,2593	0,6001	0,9104	0,8015
4	0,1632	0,7189	0,8955	0,7950

I. Evaluation

Evaluasi model sentimen pada data uji menghasilkan *macro F1-score* sebesar 0,8080 dengan akurasi 0,9307, sebagaimana ditunjukkan pada TABLE XIX. Kelas positif memperoleh performa terbaik, sedangkan kelas negatif memperoleh performa terendah, *Confusion matrix* pada Fig. 4. menunjukkan bahwa dari 25 data negatif, sebanyak 7 data salah diklasifikasikan sebagai positif, menjadi sumber utama kesalahan pada model ini.




Fig. 4. Confusion Matrix

TABLE XIX. HASIL PEMODELAN SENTIMEN

Kelas	Precision	Recall	F1-score	Support
Negative	0,7391	0,6800	0,7083	25
Neutral	0,7500	0,7500	0,7500	4
Positive	0,9600	0,9711	0,9655	173
Accuracy				0,9307
Macro Avg	0,8164	0,8004	0,8080	202
Weighted Avg	0,9285	0,9307	0,9294	202

Evaluasi model aspek pada data uji menghasilkan *macro F1-score* sebesar 0,9063, *micro F1-score* 0,9195, *Hamming*

Loss 0,0693, dan *subset accuracy* 0,7277, sebagaimana ditunjukkan pada TABLE XX. Seluruh aspek memperoleh F1-score di atas 0,78, dengan performa tertinggi pada aspek pelayanan (0,9652) dan terendah pada aspek fasilitas (0,7865).

TABLE XX. HASIL PEMODELAN ASPEK

Aspek	Precision	Recall	F1-score	Support
Fasilitas	0,7447	0,8333	0,7865	42
Harga	0,9565	0,9167	0,9362	24
Makanan	0,9922	0,8411	0,9104	151
Pelayanan	0,9823	0,9487	0,9652	117
Suasana	0,9633	0,9052	0,9333	116
Micro Avg	0,9524	0,8889	0,9195	450
Macro Avg	0,9278	0,8890	0,9063	450

IV. CONCLUSION

Penelitian ini berhasil membangun sistem *Aspect-Based Sentiment Analysis* (ABSA) pada ulasan Google Reviews Richeese Pizza di tiga cabang Kota Bandung, yaitu Riau, Buahbatu, dan Dago, melalui pendekatan *fine-tuning* IndoBERT. Data dikumpulkan menggunakan Google Maps Reviews Scraper dan menghasilkan 3.291 ulasan, yang setelah melalui tahap *preprocessing* menyisakan 2.012 data bersih. Pelabelan sentimen dilakukan secara otomatis menggunakan model *pre-trained* RoBERTa berbahasa Indonesia, sedangkan pelabelan aspek dilakukan melalui keyword matching berdasarkan kamus aspek yang disusun dengan bantuan Large Language Model. Pendekatan pelabelan otomatis ini terbukti mampu mengurangi kebutuhan anotasi manual yang biasanya memakan waktu dan tenaga.

Dua model klasifikasi yang dibangun secara terpisah menunjukkan performa yang baik. Model sentimen yang bersifat *single-label* dengan tiga kelas memperoleh akurasi 93,07% dan macro F1-score 80,80%, sedangkan model aspek yang bersifat *multi-label* dengan lima kelas memperoleh macro F1-score 90,63% dan micro F1-score 91,95% dengan Hamming Loss 0,0693. Hasil ini menunjukkan bahwa kombinasi *fine-tuning* IndoBERT, pelabelan otomatis, dan penanganan ketidakseimbangan kelas melalui *class weighting* efektif diterapkan untuk analisis sentimen berbasis aspek pada bisnis waralaba dengan banyak cabang sekaligus.

Dari sisi temuan bisnis, mayoritas ulasan pelanggan bersentimen positif (85,8%). Aspek makanan menjadi aspek yang paling banyak dibahas (34,0%), diikuti suasana (25,7%) dan pelayanan (25,3%), sementara aspek fasilitas (9,6%) dan harga (5,3%) paling jarang disinggung. Pada tingkat aspek, model mencapai performa tertinggi pada aspek pelayanan dengan F1-score 96,52% dan terendah pada aspek fasilitas dengan F1-score 78,65%. Temuan ini memberikan gambaran yang lebih spesifik mengenai prioritas perhatian pelanggan, sehingga dapat dimanfaatkan manajemen Richeese Pizza sebagai dasar evaluasi dan penentuan prioritas perbaikan layanan.

Meskipun demikian, penelitian ini masih memiliki keterbatasan. Kinerja klasifikasi pada kelas sentimen negatif menjadi sumber kesalahan utama model dengan F1-score 0,7083, di mana 7 dari 25 data negatif salah diklasifikasikan sebagai positif. Kondisi ini disebabkan oleh distribusi kelas

yang sangat tidak seimbang, mengingat jumlah ulasan negatif dan netral jauh lebih sedikit dibandingkan ulasan positif.

Untuk pengembangan selanjutnya, disarankan agar jumlah data ulasan diperbesar dan diseimbangkan, khususnya pada kelas sentimen negatif dan netral, baik melalui perluasan periode maupun cakupan cabang, agar model mampu mengenali sentimen minoritas dengan lebih akurat. Penerapan teknik penyeimbangan data lain seperti *oversampling*, data *augmentation*, atau *focal loss* juga dapat dipertimbangkan sebagai pembanding terhadap pendekatan *class weighting*. Selain itu, kualitas pelabelan aspek yang masih bergantung pada *keyword matching* dapat ditingkatkan dengan memperkaya *aspect dictionary* atau beralih ke pelabelan berbasis konteks, serta klasifikasi sentimen dan aspek dapat diintegrasikan ke dalam satu kerangka *end-to-end* agar sentimen dapat langsung dipetakan ke masing-masing aspek. Dari sisi implementasi, hasil analisis ini disarankan ditindaklanjuti manajemen dengan berfokus pada aspek yang paling sering dibahas pelanggan serta menelusuri lebih lanjut ulasan negatif pada aspek fasilitas dan pelayanan sebagai bahan perbaikan layanan yang lebih terarah.

REFERENCES

- [1] L. D. Khuc, N. T. V. Le, dan H. T. T. Nguyen, "Exploring Customer Insights Through Online Review Analytics," *International Journal of Asian Business and Information Management*, vol. 17, no. 1, hlm. 1–22, Jan 2026, doi: 10.4018/IJABIM.399855.
- [2] F. Aftab dkk., "A Comprehensive Survey on Sentiment Analysis Techniques," *International Journal of Technology*, vol. 14, no. 6, hlm. 1288, Okt 2023, doi: 10.14716/ijtech.v14i6.6632.
- [3] "Analisis Sentimen Berbasis Aspek Ulasan Produk Menggunakan CNN dan Bidirectional LSTM".
- [4] G. S. Chauhan, R. Nahta, Y. K. Meena, dan D. Gopalani, "Aspect based sentiment analysis using deep learning approaches: A survey," *Comput. Sci. Rev.*, vol. 49, hlm. 100576, Agu 2023, doi: 10.1016/j.cosrev.2023.100576.
- [5] S. Latifah, A. Erfina, dan C. Warman, "Perbandingan Hasil Aspect-Based Sentiment Analysis pada Ulasan Google Review Restoran Sunda di Bogor 323 Menggunakan Fine-Tuning IndoBERT PERBANDINGAN HASIL ASPECT-BASED SENTIMENT ANALYSIS PADA ULASAN GOOGLE REVIEW RESTORAN SUNDA DI BOGOR MENGGUNAKAN FINE-TUNING INDOBERT," vol. 31, no. 1, hlm. 2026.
- [6] C. A. Bahri dan L. H. Suadaa, "Aspect-Based Sentiment Analysis in Bromo Tengger Semeru National Park Indonesia Based on Google Maps User Reviews," *IJCCS (Indonesian Journal of Computing and Cybernetics Systems)*, vol. 17, no. 1, hlm. 79, Feb 2023, doi: 10.22146/ijccs.77354.
- [7] S. Apriliani, A. Erfina, dan C. Warman, "Fine-Tuned IndoBERT for Aspect-Based Sentiment Analysis of Indonesian Five-Star Hotel Reviews," *Jurnal Sisfokom (Sistem Informasi dan Komputer)*, vol. 14, no. 4, hlm. 437–445, Okt 2025, doi: 10.32736/sisfokom.v14i4.2491.
- [8] F. Salamah, S. Fatimah Nurdiah Permatasari, M. Afrina, dan A. Ibrahim, "METODE ASPECT-BASED SENTIMENT ANALYSIS (ABSA) PADA ULASAN SONGKET DI GOOGLE MAPS MENGGUNAKAN INDOBERT," *JATI (Jurnal Mahasiswa Teknik Informatika)*, vol. 10, no. 1, hlm. 66–74, Jan 2026, doi: 10.36040/jati.v10i1.16618.
- [9] A. Jazuli, Widowati, dan R. Kusumaningrum, "Optimizing Aspect-Based Sentiment Analysis Using BERT for Comprehensive Analysis of Indonesian Student Feedback," *Applied Sciences*, vol. 15, no. 1, hlm. 172, Des 2024, doi: 10.3390/app15010172.
- [10] Yoel Julianto, Djoni Haryadi Setiabudi, dan Silvia Rostianingsih, "Analisis Sentimen Ulasan Restoran Menggunakan Metode Support Vector Machine," *Jurnal Infra*, vol. 10, no. 1, hlm. 1–7, Jan 2022.
- [11] Bintang Sifa Amalia, Yuyun Umaidah, dan Rini Mayasari, "Analisis Sentimen Review Pelanggan Restoran Menggunakan Algoritma Support Vector Machine Dan K-Nearest Neighbor,"

SITEKIN: Jurnal Sains, Teknologi dan Industri, vol. 19, no. 1, hlm. 28–34, Nov 2021.

- [12] D. F. Salsabillah, D. E. Ratnawati, dan N. Y. Setiawan, “Analisis Sentimen Ulasan Rumah Makan Menggunakan Perbandingan Algoritma Support Vector Machine dengan Naive Bayes (Studi Kasus: Ayam Goreng Nelongso Cabang Singosari, Malang),” *Jurnal Teknologi Informasi dan Ilmu Komputer*, vol. 11, no. 1, hlm. 107–116, Feb 2024, doi: 10.25126/jtiik.20241117584.
- [13] Tri Jaka Pamungkas dan Tri Jaka Pamungkas, “Analisis Sentimen Berbasis Aspek Terhadap Ulasan Restoran Berbahasa Indonesia Menggunakan Support Vector Machines,” *eProceedings of Engineering*, vol. 8, no. 4, hlm. 4102–4114, Agu 2021.
- [14] F. Gilardi, M. Alizadeh, dan M. Kubli, “ChatGPT outperforms crowd workers for text-annotation tasks,” *Proceedings of the National Academy of Sciences*, vol. 120, no. 30, Jul 2023, doi: 10.1073/pnas.2305016120.
- [15] L. Simanihuruk dan H. Suparwito, “Long Short-Term Memory and Bidirectional Long Short-Term Memory Algorithms for Sentiment Analysis of Skintific Product Reviews,” *ITM Web of Conferences*, vol. 71, hlm. 01016, Feb 2025, doi: 10.1051/itmconf/20257101016.
- [16] C. P. Chai, “Comparison of text preprocessing methods,” *Nat. Lang. Eng.*, vol. 29, no. 3, hlm. 509–553, Mei 2023, doi: 10.1017/S1351324922000213.
- [17] Haikal Fawwaz Karim dan Adityo Permana Wibowo, “Kinerja Metode Fine-Tuning IndoBERT untuk Klasifikasi Emosi Multi-Kelas pada Teks Informal Bahasa Indonesia,” *Open Menu Bulletin of Computer Science Research*, vol. 6, no. 1, hlm. 63–74, Des 2025, doi: <https://doi.org/10.47065/bulletincsr.v6i1.850>.
- [18] Maharani Navila Salsa Bela dan Putry Wahyu Setyaningsih, “Analisis Sentimen Timnas Indonesia pada Data Tidak Seimbang Menggunakan Perbandingan Naïve Bayes dan IndoBERT,” *Journal of Computer System and Informatics (JoSYC)*, vol. 7, no. 3, hlm. 97–107, Mei 2026, doi: <https://doi.org/10.47065/josyc.v7i3.9601>.
- [19] B. S. Dewa, E. D. Wahyuni, dan N. C. Wibowo, “Klasifikasi Multi-Label Dan Ekstraksi Entitas Pada Ulasan Aplikasi Blu by BCA Digital Menggunakan IndoBERT,” *Jurnal Ilmu Komputer dan Sistem Informasi*, vol. 5, no. 2, hlm. 436–446, Mei 2026, doi: 10.70340/jirsi.v5i2.402.
- [20] Dzaki Syauqi Anthera Mumtaz dan Nuur Wachid Abdul Majid, “WEB SCRAPING DAN FINE-TUNING INDOBERT UNTUK ANALISIS SENTIMEN BERBASIS ASPEK (ABSA) PADA DATA TWITTER/X: STUDI KASUS TOPIK KURIKULUM MERDEKA,” *Rabit: Jurnal Teknologi dan Sistem Informasi Univrab*, vol. 11, no. 1, hlm. 949–963, Jan 2026, doi: 10.36341/rabit.v11i1.7155.