

Penerapan Machine Learning untuk Prediksi Penjualan Pakan Sapi MAKO Berbasis Data Time Series

Niken Nuraifah Suherlan
Department of Information System
Universitas Komputer Indonesia
Bandung, Indonesia
niken.10522018@mahasiswa.unikom.ac.id

Dzilani Wardah Pramesvari
Department of Information System
Universitas Komputer Indonesia
Bandung, Indonesia
dzilani.10522031@mahasiswa.unikom.ac.id

Mochamad Rafly Taufik Putra Fadilah
Department of Information System
Universitas Komputer Indonesia
Bandung, Indonesia
rafly.10522022@mahasiswa.unikom.ac.id

Muhammad Habib Al-Huda
Department of Information System
Universitas Komputer Indonesia
Bandung, Indonesia
habib.10522208@mahasiswa.unikom.ac.id

Abstrak—Perencanaan penjualan dan pengelolaan persediaan merupakan aspek krusial dalam industri pakan ternak, khususnya bagi usaha pakan sapi MAKO yang menghadapi fluktuasi permintaan dari waktu ke waktu. Ketidakakuratan dalam memprediksi penjualan dapat berdampak pada pemborosan biaya operasional maupun risiko kekurangan stok. Penelitian ini bertujuan untuk menerapkan pendekatan *machine learning* berbasis data deret waktu (*time series*) dalam memprediksi penjualan pakan sapi MAKO secara lebih akurat dan andal. Data yang digunakan berupa data historis penjualan harian yang kemudian melalui tahapan *pre-processing* dan *feature engineering* untuk mengekstraksi informasi temporal, seperti tahun, bulan, dan minggu penjualan. Pemodelan awal dilakukan menggunakan algoritma *Random Forest Regressor* pada data harian. Namun, hasil evaluasi menunjukkan kinerja model yang sangat rendah, ditandai dengan nilai *R-squared* sebesar 0,00 dan kesalahan prediksi yang tinggi. Untuk mengatasi permasalahan tersebut, penelitian ini mengadopsi pendekatan lanjutan dengan melakukan agregasi data ke skala mingguan serta menambahkan fitur *lagged sales* dan *moving average* guna menangkap ketergantungan temporal. Model kemudian dikembangkan menggunakan algoritma *XGBoost* dan dioptimasi melalui *hyperparameter tuning* dengan metode *GridSearchCV* dan *TimeSeriesSplit*. Hasil akhir menunjukkan peningkatan performa yang signifikan, dengan nilai *R-squared* mencapai 0,88 dan *MAPE* sebesar 6,60%, yang menandakan bahwa model mampu menjelaskan sebagian besar variasi penjualan dan menghasilkan prediksi yang akurat. Temuan ini membuktikan bahwa kombinasi rekayasa fitur deret waktu, agregasi data, dan optimasi model *machine learning* efektif digunakan sebagai sistem pendukung keputusan dalam perencanaan penjualan pakan ternak.

Kata kunci: *machine learning*, prediksi penjualan, *time series*

I. PENDAHULUAN

Perkembangan teknologi informasi dan komputasi telah membawa perubahan signifikan dalam cara organisasi dan pelaku usaha mengelola data serta mengambil keputusan strategis. Data yang sebelumnya hanya digunakan sebagai arsip kini dimanfaatkan sebagai aset penting untuk menghasilkan wawasan prediktif. Salah satu bentuk

pemanfaatan data yang berkembang pesat adalah penerapan *machine learning* dalam bidang peramalan (*forecasting*), khususnya pada data deret waktu (*time series*). Pendekatan ini memungkinkan sistem untuk mempelajari pola historis dan menghasilkan prediksi yang lebih adaptif terhadap dinamika perubahan pasar [1], [13].

Sektor perdagangan dan distribusi merupakan salah satu bidang yang sangat bergantung pada ketepatan prediksi penjualan. Kesalahan dalam memperkirakan permintaan dapat menyebabkan kelebihan stok, pemborosan biaya penyimpanan, atau bahkan kehilangan peluang penjualan akibat kekurangan persediaan. Penelitian sebelumnya menunjukkan bahwa prediksi penjualan yang akurat berperan penting dalam pengelolaan stok, perencanaan produksi, serta optimalisasi rantai pasok [3], [10], [24]. Kondisi ini juga berlaku pada sektor usaha kecil dan menengah (UMKM), yang umumnya memiliki keterbatasan sumber daya sehingga membutuhkan sistem pendukung keputusan yang efisien dan berbasis data.

Bidang pertanian dan peternakan menjadi salah satu sektor yang mulai banyak memanfaatkan pendekatan *machine learning* untuk mendukung proses perencanaan dan pengambilan keputusan. Penelitian oleh Sesilia *et al.* menunjukkan bahwa penerapan *machine learning* mampu meningkatkan akurasi prediksi jumlah penjualan dan stok pada hasil pertanian hidroponik [1]. Pendekatan serupa juga digunakan untuk memprediksi pola tanam, permintaan pasar, serta kebutuhan distribusi, yang seluruhnya bergantung pada karakteristik data deret waktu.

Karakteristik utama data penjualan adalah sifatnya yang temporal dan dinamis. Data penjualan umumnya dipengaruhi oleh faktor musiman, tren jangka panjang, serta fluktuasi jangka pendek yang tidak selalu linier. Metode statistik klasik seperti *Autoregressive Integrated Moving Average (ARIMA)* dan *Seasonal ARIMA (SARIMA)* telah lama digunakan untuk menangani peramalan data deret waktu [11], [22]. Meskipun demikian, metode tersebut memiliki keterbatasan dalam menangkap hubungan nonlinier dan kompleks yang sering muncul pada data penjualan modern [4], [8].

Kemajuan dalam bidang *machine learning* membuka peluang untuk mengatasi keterbatasan metode statistik

tradisional. Algoritma seperti *Random Forest*, *Support Vector Regression (SVR)*, *Gradient Boosting*, dan *Extreme Gradient Boosting (XGBoost)* terbukti mampu menangkap pola nonlinier dengan lebih baik dibandingkan pendekatan konvensional [3], [9], [28]. Penelitian oleh Nailendra *et al.* menunjukkan bahwa penerapan *LightGBM* yang dikombinasikan dengan *hyperparameter tuning* mampu meningkatkan akurasi prediksi penjualan ritel secara signifikan [7]. Temuan ini menegaskan pentingnya pemilihan algoritma dan proses optimasi model dalam sistem prediksi berbasis data.

Pendekatan berbasis *deep learning* juga mulai banyak digunakan dalam peramalan penjualan, terutama dengan model *Long Short-Term Memory (LSTM)* dan *Gated Recurrent Unit (GRU)*. Model ini dirancang khusus untuk menangani ketergantungan jangka panjang pada data deret waktu [12], [25], [29]. Penelitian sebelumnya menunjukkan bahwa *LSTM* unggul dalam menangkap pola temporal kompleks, terutama pada data dengan fluktuasi tinggi dan tren yang tidak stabil. Meskipun demikian, kompleksitas komputasi dan kebutuhan data yang besar menjadi tantangan tersendiri dalam implementasinya, khususnya pada skala UMKM.

Konteks UMKM menuntut solusi prediksi yang tidak hanya akurat, tetapi juga efisien dan mudah diimplementasikan. Penelitian oleh Griffin *et al.* menekankan bahwa sistem prediksi berbasis *machine learning* dapat membantu UMKM dalam mengoptimalkan inventaris dan pengambilan keputusan pemesanan barang [10]. Pendekatan serupa juga diterapkan pada berbagai sektor, seperti ritel online [7], farmasi [12], restoran [6], dan *e-commerce* [8], yang menunjukkan fleksibilitas penerapan *machine learning* dalam berbagai domain bisnis.

Usaha pakan sapi MAKO merupakan salah satu contoh UMKM yang menghadapi tantangan fluktuasi permintaan penjualan dari waktu ke waktu. Penjualan pakan ternak dipengaruhi oleh berbagai faktor, seperti siklus pemeliharaan ternak, musim, kondisi ekonomi peternak, serta pola distribusi. Ketidakpastian ini menyulitkan pelaku usaha dalam menentukan jumlah produksi dan persediaan yang optimal. Tanpa dukungan sistem prediksi yang memadai, keputusan bisnis cenderung bersifat intuitif dan berisiko tinggi.

Pendekatan *time series forecasting* menjadi sangat relevan dalam konteks prediksi penjualan pakan ternak. Data historis penjualan yang tersimpan secara kronologis memungkinkan model untuk mempelajari pola masa lalu dan menggunakannya sebagai dasar prediksi masa depan. Penelitian oleh Hidayat *et al.* menunjukkan bahwa model *Prophet* mampu menangkap tren dan musiman penjualan restoran dengan baik [6]. Studi lain membandingkan berbagai algoritma, seperti *SARIMA* dan *Prophet*, untuk peramalan penjualan produk digital dan menemukan bahwa performa model sangat bergantung pada karakteristik data dan skala waktu yang digunakan [27].

Pemilihan skala waktu merupakan faktor penting dalam pemodelan data deret waktu. Data harian sering kali mengandung fluktuasi ekstrem yang dapat mengganggu proses pembelajaran model. Beberapa penelitian menunjukkan bahwa agregasi data ke skala mingguan atau bulanan dapat membantu menonjolkan pola tren yang lebih stabil dan meningkatkan performa model prediksi [4], [8]. Pendekatan ini juga memungkinkan penerapan fitur tambahan, seperti *lagged variables* dan *moving average*, yang berperan penting dalam menangkap ketergantungan temporal.

Rekayasa fitur (*feature engineering*) menjadi salah satu tahap krusial dalam pengembangan model *machine learning*. Fitur berbasis waktu, seperti tahun, bulan, dan minggu, serta fitur historis seperti penjualan periode sebelumnya, terbukti mampu meningkatkan akurasi prediksi secara signifikan [16], [30]. Penelitian oleh Wijaya *et al.* menunjukkan bahwa optimasi parameter pada model *XGBoost* dapat menghasilkan peningkatan performa yang substansial dalam prediksi penjualan ritel [30]. Hal ini menegaskan bahwa keberhasilan model tidak hanya ditentukan oleh algoritma, tetapi juga oleh kualitas fitur dan proses optimasi yang diterapkan.

Berdasarkan tinjauan literatur yang telah dilakukan, sebagian besar penelitian berfokus pada perbandingan algoritma atau penerapan model tertentu pada sektor spesifik. Penelitian yang mengkaji secara sistematis proses transisi dari model dengan performa rendah menuju model yang optimal melalui agregasi data dan *hyperparameter tuning* masih relatif terbatas, khususnya pada konteks UMKM pakan ternak. Kesenjangan ini menunjukkan adanya peluang penelitian untuk mengeksplorasi strategi pemodelan yang lebih adaptif dan aplikatif.


Penelitian ini bertujuan untuk menerapkan pendekatan *machine learning* berbasis *time series* dalam memprediksi penjualan pakan sapi MAKO. Fokus penelitian tidak hanya pada pemilihan algoritma, tetapi juga pada proses rekayasa fitur, pemilihan skala waktu, serta optimasi model melalui *hyperparameter tuning*. Algoritma *Random Forest* digunakan sebagai model awal untuk mengevaluasi kemampuan dasar dalam mempelajari pola data, kemudian dikembangkan lebih lanjut menggunakan *XGBoost* yang dioptimasi dengan metode *GridSearchCV* dan *TimeSeriesSplit*.

Kontribusi utama penelitian ini terletak pada penyajian proses pemodelan yang komprehensif dan terstruktur, mulai dari eksplorasi data hingga evaluasi performa model. Hasil penelitian diharapkan dapat menjadi referensi bagi pelaku UMKM, akademisi, maupun praktisi dalam mengembangkan sistem prediksi penjualan yang akurat dan berbasis data. Penerapan model prediksi yang andal diharapkan mampu mendukung pengambilan keputusan strategis, meningkatkan efisiensi operasional, serta memperkuat daya saing usaha pakan ternak di tengah dinamika pasar yang terus berubah.

II. METODE PENELITIAN

Penelitian ini menggunakan pendekatan kuantitatif dengan metode eksperimen berbasis data deret waktu (*time series*) untuk memprediksi penjualan pakan sapi MAKO. Data yang digunakan berupa data historis penjualan yang dikumpulkan secara periodik dan diolah melalui tahapan *pre-processing*, meliputi konversi format waktu dan pembersihan data. Rekayasa fitur (*feature engineering*) dilakukan dengan mengekstraksi fitur temporal serta membangun fitur historis berupa *lagged variables* dan *moving average* guna menangkap ketergantungan waktu pada data. Pemodelan awal dilakukan menggunakan algoritma *Random Forest Regressor* sebagai pembanding kinerja dasar, kemudian dikembangkan menggunakan algoritma *Extreme Gradient Boosting (XGBoost)* dengan agregasi data mingguan untuk mengurangi fluktuasi ekstrem. Proses pelatihan dan evaluasi model dilakukan dengan membagi data menjadi data latih dan data uji secara kronologis menggunakan metode *TimeSeriesSplit* agar tidak terjadi kebocoran data masa depan. Optimasi model

dilakukan melalui *hyperparameter tuning* menggunakan *GridSearchCV* untuk memperoleh konfigurasi parameter terbaik. Kinerja model dievaluasi menggunakan metrik *Mean Absolute Error (MAE)*, *Root Mean Squared Error (RMSE)*, *Mean Absolute Percentage Error (MAPE)*, dan *R-squared* untuk menilai tingkat akurasi dan kemampuan model dalam menjelaskan variasi data penjualan. Alur lengkap pemrosesan data dan Pembangunan model ditunjukkan pada Gambar 1.



Gambar 1 Alur Proses Penelitian

A. Data Historis Penjualan

No	Tanggal	Jumlah Penjualan
1	02-Feb-2024	6,740
2	15-Feb-2024	5,700
3	16-Feb-2024	13,160
4	17-Feb-2024	6,000
5	18-Feb-2024	4,380
6	19-Feb-2024	23,194
7	20-Feb-2024	13,730
8	21-Feb-2024	2,020
9	22-Feb-2024	8,980
10	23-Feb-2024	720

Gambar 2. Dataset Penjualan Pakan Sapi MAKO

Tahap awal penelitian dimulai dengan pengumpulan data historis penjualan pakan sapi MAKO yang tersusun secara kronologis berdasarkan waktu. Data ini berfungsi sebagai dasar utama dalam pemodelan prediksi karena memuat informasi pola penjualan masa lalu yang akan digunakan untuk mempelajari kecenderungan dan dinamika penjualan pada periode berikutnya.

B. Pre-processing

Tahap *pre-processing* dilakukan untuk memastikan kualitas dan kesiapan data sebelum digunakan dalam pemodelan. Proses ini meliputi konversi format tanggal ke tipe data waktu, pemeriksaan data hilang, serta penyesuaian struktur data agar sesuai dengan kebutuhan analisis deret waktu (*time series*). Tahap ini bertujuan untuk mengurangi potensi kesalahan yang dapat memengaruhi kinerja model.

C. Feature Engineering

Tahap *feature engineering* bertujuan untuk mengekstraksi dan membangun fitur-fitur yang relevan dari data penjualan. Fitur yang dibentuk meliputi fitur temporal, seperti tahun, bulan, dan minggu, serta fitur historis berupa *lagged sales* dan *moving average*. Fitur-fitur ini dirancang untuk menangkap pola musiman, tren, dan ketergantungan temporal dalam data penjualan.

D. Pemodelan Awal (Random Forest)

Pemodelan awal dilakukan menggunakan algoritma *Random Forest Regressor* sebagai model pembanding dasar. Model ini digunakan untuk mengevaluasi kemampuan awal algoritma *machine learning* dalam mempelajari pola penjualan berdasarkan fitur yang telah dibentuk. Hasil dari tahap ini menjadi acuan dalam menilai kebutuhan pengembangan model lanjutan.

E. Pemodelan Lanjutan (XGBoost)

Tahap pemodelan lanjutan dilakukan dengan menggunakan algoritma *Extreme Gradient Boosting (XGBoost)*. Pada tahap ini, data telah melalui agregasi mingguan dan proses optimasi parameter (*hyperparameter tuning*) untuk meningkatkan akurasi prediksi. Model ini dirancang untuk menangkap hubungan nonlinier yang kompleks serta meningkatkan kemampuan generalisasi terhadap data baru.

F. Evaluasi Model

Tahap akhir penelitian adalah evaluasi model untuk menilai kinerja prediksi yang dihasilkan. Evaluasi dilakukan menggunakan metrik *Mean Absolute Error (MAE)*, *Root Mean Squared Error (RMSE)*, *Mean Absolute Percentage Error (MAPE)*, dan *R-squared*. Hasil evaluasi digunakan untuk menentukan tingkat akurasi dan kelayakan model dalam mendukung prediksi penjualan pakan sapi MAKO.


III. HASIL DAN PEMBAHASAN

Bab ini membahas hasil penelitian yang diperoleh dari penerapan metode *machine learning* berbasis data deret waktu (*time series*) untuk memprediksi penjualan pakan sapi MAKO. Pembahasan dilakukan secara sistematis, dimulai dari hasil *pre-processing* dan analisis data eksplorasi, pemodelan awal menggunakan *Random Forest*, pengembangan model lanjutan menggunakan *XGBoost*, hingga evaluasi performa model setelah dilakukan *hyperparameter tuning*. Setiap tahapan dianalisis secara kritis untuk menjelaskan pengaruh metode yang digunakan terhadap kinerja prediksi.

A. Hasil Pre-processing dan Analisis Data Eksplorasi

Tahap awal penelitian menghasilkan data penjualan yang telah melalui proses *pre-processing* sehingga siap digunakan dalam analisis lanjutan. Konversi kolom tanggal ke format waktu memungkinkan data diperlakukan sebagai data deret waktu (*time series*), yang menjadi prasyarat utama dalam pemodelan prediksi berbasis temporal. Proses pembersihan data memastikan tidak terdapat nilai kosong (*missing values*) yang dapat mengganggu proses pelatihan model.

Analisis data eksplorasi (*Exploratory Data Analysis / EDA*) dilakukan untuk memahami karakteristik dasar data penjualan. Visualisasi deret waktu menunjukkan bahwa penjualan pakan sapi MAKO memiliki fluktuasi yang cukup tinggi pada skala harian. Pola penjualan tidak bersifat linier dan menunjukkan adanya lonjakan serta penurunan tajam pada periode tertentu. Kondisi ini mengindikasikan bahwa data bersifat *noisy* dan dipengaruhi oleh berbagai faktor eksternal, seperti siklus pemeliharaan ternak, waktu distribusi, dan kondisi pasar.




Gambar 3. Jumlah Penjualan Berdasarkan Hari dalam Minggu Penjualan Harian Pakan Sapi MAKO

Hasil EDA juga menunjukkan bahwa pola musiman tidak selalu terlihat jelas pada skala harian. Hal ini menguatkan asumsi bahwa pemodelan langsung menggunakan data harian berpotensi menghasilkan performa prediksi yang rendah. Temuan ini sejalan dengan beberapa penelitian sebelumnya yang menyatakan bahwa data dengan fluktuasi ekstrem memerlukan pendekatan agregasi atau rekayasa fitur tambahan agar pola temporal lebih mudah dipelajari oleh model *machine learning*.

B. Hasil Pemodelan Awal Menggunakan Random Forest

Pemodelan awal dilakukan menggunakan algoritma *Random Forest Regressor* dengan memanfaatkan fitur temporal dasar, seperti tahun, bulan, hari, dan hari dalam minggu. Model ini digunakan sebagai *baseline model* untuk mengevaluasi kemampuan awal algoritma *machine learning* dalam mempelajari pola penjualan pakan sapi MAKO.

Hasil evaluasi menunjukkan bahwa model *Random Forest* menghasilkan nilai *Mean Absolute Error (MAE)* yang relatif besar, dengan nilai *Root Mean Squared Error (RMSE)* yang juga tinggi. Nilai *R-squared* yang diperoleh sebesar 0,00 menunjukkan bahwa model tidak mampu menjelaskan variasi data penjualan dan kinerjanya setara dengan memprediksi nilai rata-rata penjualan. Nilai *Mean Absolute Percentage Error (MAPE)* yang sangat tinggi mengindikasikan bahwa prediksi model sering kali meleset jauh dari nilai aktual.



Gambar 4. Perbandingan Nilai Aktual dan Prediksi Model Random Forest

Hasil pemodelan menggunakan algoritma *Random Forest Regressor* menunjukkan kinerja yang sangat rendah dalam memprediksi penjualan pakan sapi MAKO. Nilai *Man Absolute Error (MAE)* sebesar 4.597,24 mengindikasikan bahwa rata-rata kesalahan absolut prediksi mencapai sekitar 4.957 unit penjualan, yang berarti setiap prediksi model meleset sekitar 4–5 ribu unit dari nilai sebenarnya, suatu kesalahan yang tergolong besar jika dibandingkan dengan skala data penjualan. Nilai *Mean Squared Error (MSE)* sebesar 34.261.800,71 dan *Root*

Mean Squared Error (RMSE) sebesar 5.853,36 menunjukkan adanya kesalahan prediksi yang sangat besar pada beberapa titik tertentu, di mana nilai *RMSE* yang lebih tinggi daripada *MAE* mengindikasikan keberadaan *outlier* serta ketidakmampuan model dalam memprediksi nilai ekstrem seperti lonjakan atau penurunan penjualan secara tajam. Nilai *R-squared* sebesar 0,00 menandakan bahwa model sama sekali tidak mampu menjelaskan variasi data penjualan, sehingga kinerjanya setara dengan sekadar menebak nilai rata-rata, yang dalam konteks statistik merupakan indikator kegagalan model. Kondisi ini diperparah dengan nilai *Mean Absolute Percentage Error (MAPE)* sebesar 227,35%, yang menunjukkan bahwa secara rata-rata kesalahan prediksi melebihi 200% dari nilai aktual, menandakan prediksi sering kali meleset lebih dari dua kali lipat. Kegagalan ini menunjukkan bahwa penggunaan fitur waktu dasar tanpa mempertimbangkan ketergantungan temporal antarperiode tidak cukup untuk memodelkan data deret waktu (*time series*) penjualan. Algoritma *Random Forest*, meskipun kuat dalam menangkap hubungan nonlinier, cenderung memperlakukan setiap observasi sebagai entitas independen, sehingga gagal memahami tren dan pola berurutan yang menjadi karakteristik utama data *time series*. Temuan ini menegaskan bahwa pemodelan deret waktu memerlukan fitur historis yang secara eksplisit merepresentasikan hubungan antarperiode, dan berdasarkan hasil evaluasi tersebut, model ini dinyatakan gagal serta tidak layak digunakan untuk prediksi operasional.

C. Peralihan ke Agregasi Mingguan dan Rekayasa Fitur Temporal

Berdasarkan hasil pemodelan awal menggunakan algoritma *Random Forest Regressor* yang menunjukkan kinerja sangat rendah dengan nilai *R-squared* sebesar 0,00, dapat disimpulkan bahwa model gagal mempelajari pola penjualan secara efektif. Kegagalan ini terjadi karena fitur yang digunakan masih bersifat sangat dasar, yaitu hanya fitur waktu seperti tahun, bulan, dan hari dalam minggu, tanpa memasukkan fitur yang secara eksplisit menangkap ketergantungan temporal antarperiode. Tanpa adanya fitur historis, model cenderung memperlakukan setiap observasi harian sebagai entitas independen, sehingga tidak mampu menangkap tren dan pola musiman yang merupakan karakteristik utama data deret waktu (*time series*).

Untuk mengatasi permasalahan tersebut, penelitian ini melakukan peralihan pendekatan dengan mengagregasi data penjualan ke skala mingguan. Keputusan ini didasarkan pada asumsi bahwa pola penjualan akan lebih jelas dan stabil pada skala mingguan dibandingkan skala harian yang cenderung sangat fluktuatif. Selain itu, dengan jumlah data yang relatif terbatas, agregasi mingguan membantu menonjolkan tren makro serta mengurangi *noise* yang dapat mengganggu proses pembelajaran model.

Setelah proses agregasi mingguan dilakukan, tahapan rekayasa fitur (*feature engineering*) lanjutan diterapkan dengan membangun fitur temporal dan fitur historis. Fitur yang dibentuk meliputi fitur waktu mingguan, seperti tahun, bulan, dan minggu dalam tahun, serta fitur historis berupa *lagged sales* dan *moving average*. Fitur *lagged sales* mencakup penjualan satu minggu, dua minggu, dan empat minggu sebelumnya, yang bertujuan untuk menangkap ketergantungan temporal dan momentum penjualan. Sementara itu, fitur *moving average* dua minggu dan empat minggu digunakan untuk menghaluskan fluktuasi jangka pendek serta merepresentasikan tren jangka pendek dan menengah secara lebih stabil. Kombinasi fitur-fitur ini menjadi komponen kunci yang memungkinkan model


mempelajari pola temporal secara lebih efektif pada skala mingguan.

D. Hasil Pemodelan XGBoost Sebelum Hyperparameter Tuning

Setelah data diagregasi secara mingguan dan fitur temporal tambahan dibangun, proses pemodelan dilanjutkan menggunakan algoritma *Extreme Gradient Boosting (XGBoost)*. Algoritma ini dipilih karena dikenal memiliki kemampuan yang kuat dalam menangani dataset dengan banyak fitur, menemukan hubungan nonlinier yang kompleks, serta sering digunakan sebagai metode *state-of-the-art* dalam berbagai penelitian *machine learning*.

Hasil evaluasi model XGBoost dengan konfigurasi parameter awal menunjukkan bahwa performa model masih tergolong buruk. Nilai *Mean Absolute Error (MAE)* sebesar 16.223,64 menunjukkan bahwa rata-rata kesalahan prediksi masih sangat besar, sedangkan nilai *Root Mean Squared Error (RMSE)* sebesar 20.532,78 mengindikasikan adanya kesalahan ekstrem yang signifikan pada beberapa titik prediksi. Nilai *R-squared* sebesar -1,01 menunjukkan bahwa model memiliki kinerja yang lebih buruk dibandingkan model yang hanya memprediksi nilai rata-rata penjualan. Selain itu, nilai *Mean Absolute Percentage Error (MAPE)* sebesar 23,54% menandakan bahwa kesalahan prediksi relatif masih tinggi secara persentase.

Weekly Mean Absolute Error (MAE): 16223.64
Weekly Mean Squared Error (MSE): 421595136.00
Weekly Root Mean Squared Error (RMSE): 20532.78
Weekly R-squared (R2 Score): -1.01
Weekly Mean Absolute Percentage Error (MAPE): 23.54%



Gambar 5. Hasil Prediksi XGBoost Sebelum Hyperparameter Tuning

Hasil ini menunjukkan bahwa meskipun algoritma XGBoost secara teoritis lebih canggih dibandingkan *Random Forest*, penggunaan parameter default belum mampu menyesuaikan diri dengan karakteristik data penjualan pakan sapi MAKO. Temuan ini menegaskan bahwa pemilihan algoritma yang kuat saja tidak cukup, melainkan harus disertai dengan proses optimasi parameter agar model dapat mencapai performa yang optimal.

Hasil pemodelan awal menggunakan algoritma *Extreme Gradient Boosting (XGBoost)* menunjukkan bahwa model belum mampu menghasilkan prediksi yang optimal.

Berdasarkan hasil evaluasi, nilai *Mean Absolute Error (MAE)* sebesar 16.223,64 menunjukkan bahwa rata-rata prediksi model meleset sekitar 16 ribu unit dari nilai penjualan aktual. Jika dibandingkan dengan rentang data penjualan, tingkat kesalahan ini tergolong besar dan mengindikasikan rendahnya akurasi model.

Nilai *Mean Squared Error (MSE)* sebesar 421.595.136,00 memperlihatkan adanya beberapa kesalahan prediksi yang sangat ekstrem. Karena MSE mengkuadratkan setiap kesalahan, nilai yang besar menandakan bahwa model gagal menangkap pola pada beberapa titik data penting. Hal ini diperkuat oleh nilai *Root Mean Squared Error (RMSE)* sebesar 20.532,78 yang menunjukkan bahwa ukuran rata-rata kesalahan prediksi masih sangat tinggi.

Selain itu, nilai *R-squared* sebesar -1,01 mengindikasikan bahwa model memiliki kinerja yang sangat buruk, bahkan lebih rendah dibandingkan model sederhana yang hanya memprediksi nilai rata-rata penjualan. Nilai negatif pada koefisien determinasi menandakan bahwa model tidak mampu menjelaskan variabilitas data dengan baik.

Sementara itu, nilai *Mean Absolute Percentage Error (MAPE)* sebesar 23,54% menunjukkan bahwa rata-rata prediksi meleset sekitar 23,54% dari nilai aktual. Meskipun persentase ini tidak setinggi kesalahan absolut, angka tersebut tetap menunjukkan bahwa model belum layak digunakan sebagai alat prediksi operasional. Secara keseluruhan, hasil evaluasi ini menegaskan bahwa model XGBoost dengan konfigurasi awal masih memiliki performa yang rendah dan memerlukan proses optimasi lebih lanjut.

E. Hyperparameter Tuning Menggunakan GridSearchCV

Untuk meningkatkan kinerja model XGBoost, dilakukan proses *hyperparameter tuning* menggunakan metode *GridSearchCV* dengan pendekatan *TimeSeriesSplit*. Penggunaan *TimeSeriesSplit* bertujuan untuk menjaga urutan kronologis data sehingga tidak terjadi kebocoran informasi dari periode masa depan ke periode masa lalu, yang sangat penting dalam pemodelan data deret waktu.

Parameter yang dioptimasi dalam penelitian ini meliputi jumlah pohon (*n_estimators*), tingkat pembelajaran (*learning rate*), kedalaman maksimum pohon (*max_depth*), rasio pengambilan sampel data (*subsample*), dan rasio pemilihan fitur (*colsample_bytree*). *GridSearchCV* bekerja dengan mengevaluasi seluruh kombinasi parameter yang telah ditentukan menggunakan metrik *neg_mean_squared_error*, sehingga kombinasi parameter terbaik dipilih berdasarkan kemampuan model dalam meminimalkan kesalahan prediksi selama proses *cross-validation*.

```
# THE CODE: HYPERPARAMETER TUNING USING GRIDSEARCHCV TO IMPROVE XGBOOST PERFORMANCE
# A higher negative MSE means a lower (better) MSE.
grid_search = GridSearchCV(estimator=xgb_model,
                           param_grid=param_grid,
                           scoring='neg_mean_squared_error',
                           cv=cvsplit,
                           verbose=1,
                           n_jobs=-1) # Use all available cores

# Fit GridSearchCV to the full weekly dataset
print("Starting GridSearchCV...")
grid_search.fit(X_weekly_tuned, y_weekly_tuned)
print("GridSearchCV completed.")

# Print the best parameters and best score
print("Unbest parameters found:", grid_search.best_params_)
print("Best negative MSE score (from GridSearchCV):", grid_search.best_score_)
print("Corresponding RMSE:", np.sqrt(-grid_search.best_score_))

Starting GridSearchCV...
Fitting 3 folds for each of 243 candidates, totalling 729 fits
GridSearchCV completed.

Best parameters found: {'colsample_bytree': 0.7, 'learning_rate': 0.01, 'max_depth': 3, 'n_estimators': 300, 'subsample': 0.8}
Best negative MSE score (from GridSearchCV): -414198666.6666667
Corresponding RMSE: 20351.67478775895
```

Weekly Mean Absolute Error (MAE): 4450.39
 Weekly Mean Squared Error (MSE): 25156598.00
 Weekly Root Mean Squared Error (RMSE): 5015.64
 Weekly R-squared (R2 Score): 0.88
 Weekly Mean Absolute Percentage Error (MAPE): 6.60%

Gambar 6. Hyperparameter Tuning Menggunakan GridSearchCV

Setelah proses GridSearchCV dijalankan pada seluruh dataset mingguan, sistem berhasil mengidentifikasi kombinasi hyperparameter terbaik yang mampu menghasilkan kinerja model paling optimal berdasarkan hasil cross-validation. Konfigurasi parameter tersebut terdiri dari `colsample_bytree` sebesar 0,7, `learning_rate` sebesar 0,01, `max_depth` sebesar 3, `n_estimators` sebanyak 300, serta `subsample` sebesar 0,8. Kombinasi ini kemudian digunakan untuk membangun model XGBoost final dengan harapan mampu meningkatkan akurasi prediksi secara signifikan.

Hasil evaluasi menunjukkan adanya peningkatan performa model yang sangat jelas setelah dilakukan hyperparameter tuning. Salah satu indikator paling kuat terlihat pada nilai R-squared yang mengalami lonjakan dari -1,01 menjadi 0,88. Perubahan ini menandakan bahwa model yang telah dioptimasi kini mampu menjelaskan sekitar 88% variasi dalam data penjualan mingguan. Jika sebelumnya model memiliki kinerja yang lebih buruk dibandingkan pendekatan sederhana yang hanya memprediksi nilai rata-rata, maka setelah tuning model menunjukkan kemampuan yang jauh lebih baik dalam menangkap pola data.

Penurunan kesalahan prediksi juga terlihat pada nilai Root Mean Squared Error (RMSE), yang berkurang secara drastis dari 20.532,78 menjadi 5.015,64. Hal ini menunjukkan bahwa rata-rata ukuran kesalahan prediksi telah menurun secara signifikan, sehingga jarak antara nilai prediksi dan nilai aktual menjadi semakin kecil. Bahkan, nilai RMSE model hasil tuning tercatat lebih rendah dibandingkan model Random Forest awal yang memiliki RMSE sebesar 5.853,36, meskipun keduanya menggunakan skala agregasi data yang berbeda.

Perbaikan kinerja model turut diperkuat oleh penurunan nilai Mean Absolute Error (MAE) dari 16.223,64 menjadi 4.450,39. Penurunan ini mengonfirmasi bahwa rata-rata selisih absolut antara hasil prediksi dan data aktual telah berkurang secara substansial. Dengan demikian, model tidak hanya mengalami peningkatan secara statistik, tetapi juga menjadi lebih reliabel untuk digunakan dalam konteks prediksi penjualan.


Selain itu, nilai Mean Absolute Percentage Error (MAPE) juga menunjukkan peningkatan akurasi yang signifikan dengan penurunan dari 23,54% menjadi 6,60%. Angka tersebut mengindikasikan bahwa secara rata-rata prediksi model hanya meleset sekitar 6,6% dari nilai penjualan aktual, yang dapat dikategorikan sebagai tingkat akurasi yang sangat baik dalam pemodelan prediksi penjualan.

Secara keseluruhan, perbandingan performa sebelum dan sesudah hyperparameter tuning menegaskan bahwa proses optimasi parameter memiliki peran krusial dalam meningkatkan kualitas model machine learning. Model XGBoost yang telah dioptimasi tidak hanya mampu menjelaskan variabilitas data dengan lebih baik, tetapi juga menghasilkan prediksi yang lebih akurat dan stabil. Temuan ini memperlihatkan bahwa pemilihan konfigurasi parameter yang tepat merupakan faktor penting dalam membangun model prediksi yang andal.

F. Hasil Pemodelan XGBoost Setelah Hyperparameter Tuning

Hasil evaluasi model XGBoost setelah dilakukan *hyperparameter tuning* menunjukkan peningkatan performa yang sangat signifikan. Nilai R-squared meningkat drastis dari -1,01 menjadi 0,88, yang berarti model mampu menjelaskan 88% variasi penjualan pakan sapi MAKO pada skala mingguan. Penurunan nilai RMSE dari 20.532,78 menjadi 5.015,64 serta penurunan MAE dari 16.223,64 menjadi 4.450,39 menunjukkan bahwa kesalahan prediksi model menjadi jauh lebih kecil dan stabil.

Nilai MAPE yang menurun dari 23,54% menjadi 6,60% mengindikasikan bahwa secara rata-rata prediksi model hanya meleset sekitar enam persen dari nilai penjualan aktual, yang merupakan tingkat akurasi sangat baik untuk konteks UMKM dengan dinamika permintaan yang tinggi.



Gambar 7. Perbandingan Penjualan Aktual dan Prediksi XGBoost Setelah Hyperparameter Tuning

Visualisasi hasil prediksi menunjukkan bahwa garis prediksi mengikuti tren penjualan aktual dengan sangat baik, serta mampu menangkap puncak dan penurunan penjualan secara konsisten. Keberhasilan ini menunjukkan bahwa kombinasi agregasi data mingguan, rekayasa fitur temporal berbasis *lagged sales* dan *moving average*, serta optimasi parameter melalui *hyperparameter tuning* memberikan dampak positif yang signifikan terhadap performa model prediksi.

Visualisasi hasil prediksi model XGBoost yang sudah di-tuning (scatter plot dan line plot deret waktu) juga secara jelas menunjukkan peningkatan ini. Titik-titik pada *scatter plot* akan terlihat jauh lebih rapat di sekitar garis 'prediksi sempurna ($y=x$)', dan garis prediksi pada *line plot* akan mengikuti tren penjualan aktual dengan sangat baik, menangkap puncak dan lembah dengan akurat.

G. Hasil Pembahasan

Hasil penelitian ini menunjukkan bahwa keberhasilan pemodelan prediksi penjualan pakan sapi MAKO sangat dipengaruhi oleh pemilihan pendekatan pemodelan, skala waktu data, serta strategi rekayasa fitur yang digunakan.

Pada tahap awal, penggunaan algoritma *Random Forest Regressor* dengan fitur waktu dasar menghasilkan kinerja yang sangat rendah, ditandai dengan nilai *R-squared* sebesar 0,00 dan kesalahan prediksi yang tinggi. Temuan ini mengindikasikan bahwa model gagal mempelajari pola yang bermakna dari data penjualan. Secara konseptual, kondisi ini terjadi karena data deret waktu (*time series*) memiliki ketergantungan antarperiode yang tidak dapat ditangkap hanya dengan fitur kalender sederhana [1], [3].

Kegagalan model awal menegaskan bahwa data penjualan tidak dapat diperlakukan sebagai data tabular statis. Algoritma *Random Forest*, meskipun unggul dalam menangkap hubungan nonlinier, cenderung memperlakukan setiap observasi sebagai entitas independen apabila tidak disertai fitur historis. Akibatnya, model tidak mampu memahami tren jangka panjang maupun pola musiman yang menjadi karakteristik utama data penjualan [4], [8]. Hasil ini sejalan dengan penelitian sebelumnya yang menyatakan bahwa pemodelan *time series* membutuhkan fitur yang secara eksplisit merepresentasikan hubungan temporal agar model dapat belajar secara efektif [11], [16].

Peralihan ke agregasi data mingguan merupakan langkah strategis yang memberikan dampak signifikan terhadap stabilitas data. Agregasi ini terbukti mampu mengurangi fluktuasi ekstrem yang muncul pada data harian serta menonjolkan tren makro yang lebih relevan untuk perencanaan operasional. Beberapa penelitian terdahulu juga menyebutkan bahwa agregasi data ke skala waktu yang lebih besar dapat meningkatkan performa model prediksi, terutama ketika data bersifat *noisy* dan jumlah observasi relatif terbatas [6], [27]. Dalam konteks penelitian ini, agregasi mingguan memungkinkan pola penjualan pakan ternak terlihat lebih konsisten dan mudah dipelajari oleh model.

Rekayasa fitur (*feature engineering*) lanjutan menjadi faktor kunci yang membedakan model lanjutan dari model awal. Penambahan fitur *lagged sales* dan *moving average* memungkinkan model untuk menangkap ketergantungan temporal yang sebelumnya tidak terwakili. Fitur *lagged sales* memberikan informasi historis langsung mengenai penjualan pada periode sebelumnya, yang secara empiris sering menjadi prediktor kuat bagi penjualan pada periode saat ini [12], [15]. Sementara itu, fitur *moving average* berfungsi untuk menghaluskan fluktuasi jangka pendek dan memberikan representasi tren yang lebih stabil, sehingga membantu model dalam memahami arah pergerakan penjualan [16].

Meskipun demikian, hasil pemodelan *XGBoost* sebelum dilakukan *hyperparameter tuning* menunjukkan bahwa penggunaan algoritma yang lebih canggih belum tentu langsung menghasilkan performa yang optimal. Nilai *R-squared* yang negatif serta tingginya nilai *MAE* dan *RMSE* mengindikasikan bahwa konfigurasi parameter default belum sesuai dengan karakteristik data penjualan pakan sapi MAKO. Temuan ini menegaskan bahwa performa *machine learning* tidak hanya bergantung pada jenis algoritma, tetapi juga pada kesesuaian parameter model terhadap data yang digunakan [7], [30].

Proses *hyperparameter tuning* menggunakan *GridSearchCV* dan *TimeSeriesSplit* menjadi titik balik utama dalam penelitian ini. Penggunaan *TimeSeriesSplit* memastikan bahwa proses validasi dilakukan secara kronologis, sehingga tidak terjadi kebocoran informasi dari

masa depan ke masa lalu. Pendekatan ini sangat penting dalam pemodelan *time series* dan telah direkomendasikan secara luas dalam literatur [2], [4]. Sementara itu, *GridSearchCV* memungkinkan eksplorasi sistematis terhadap berbagai kombinasi parameter untuk menemukan konfigurasi terbaik yang meminimalkan kesalahan prediksi.

Tabel 1. Perbandingan *TimeSeriesSplit* dan *GridSearchCV*

Aspek	<i>TimeSeriesSplit</i>	<i>GridSearchCV</i>
Jenis Metode	Teknik validasi silang khusus data deret waktu	Metode pencarian hyperparameter secara sistematis
Fungsi Utama	Membagi data secara kronologis menjadi data latih dan data uji	Mencari kombinasi hyperparameter terbaik
Cara Kerja	Data dilatih menggunakan periode waktu sebelumnya dan diuji pada periode setelahnya	Menguji seluruh kombinasi parameter dalam parameter grid
Tujuan Penggunaan	Menghindari kebocoran data masa depan	Mengoptimalkan performa model
Kelebihan	Menjaga urutan temporal sehingga lebih realistis untuk prediksi <i>time series</i>	Memberikan konfigurasi parameter dengan performa terbaik
Peran dalam Penelitian	Digunakan sebagai strategi validasi model	Digunakan untuk menentukan hyperparameter optimal <i>XGBoost</i>
Hasil yang Diharapkan	Evaluasi model yang lebih akurat	Model dengan kesalahan prediksi minimal

Hasil *hyperparameter tuning* menunjukkan peningkatan performa model yang sangat signifikan, dengan nilai *R-squared* meningkat menjadi 0,88 dan nilai *MAPE* menurun hingga 6,60%. Secara statistik, nilai *R-squared* tersebut menunjukkan bahwa model mampu menjelaskan sebagian besar variasi penjualan mingguan, sementara nilai *MAPE* yang rendah mengindikasikan tingkat akurasi prediksi yang sangat baik. Peningkatan ini membuktikan bahwa kombinasi algoritma *XGBoost*, rekayasa fitur temporal yang tepat, serta optimasi parameter merupakan pendekatan yang efektif dalam memodelkan data penjualan pakan ternak [7], [31].

Visualisasi hasil prediksi juga memperkuat temuan kuantitatif yang diperoleh. Garis prediksi model *XGBoost* setelah dilakukan *tuning* mengikuti tren penjualan aktual dengan sangat baik dan mampu menangkap puncak serta penurunan penjualan secara konsisten. Hal ini menunjukkan bahwa model tidak hanya unggul dalam mengurangi kesalahan numerik, tetapi juga mampu merepresentasikan dinamika penjualan secara realistis.

Temuan ini sejalan dengan penelitian sebelumnya yang menyatakan bahwa *gradient boosting* yang dioptimasi mampu memberikan performa prediksi yang stabil pada berbagai sektor bisnis [28], [30].

Dari perspektif praktis, hasil penelitian ini memiliki implikasi yang penting bagi pelaku UMKM, khususnya usaha pakan ternak. Model prediksi penjualan mingguan yang akurat dapat digunakan sebagai sistem pendukung keputusan dalam perencanaan produksi, pengelolaan persediaan, dan strategi distribusi. Dengan mengetahui estimasi permintaan secara lebih presisi, pelaku usaha dapat mengurangi risiko kelebihan stok maupun kekurangan pasokan, sehingga efisiensi operasional dapat ditingkatkan [10], [24].

Secara akademik, penelitian ini menegaskan pentingnya pendekatan holistik dalam pemodelan *machine learning* berbasis *time series*. Kegagalan model awal menunjukkan bahwa pemilihan algoritma tanpa rekayasa fitur dan optimasi yang memadai tidak akan menghasilkan kinerja yang optimal. Sebaliknya, keberhasilan model akhir membuktikan bahwa integrasi antara agregasi data, fitur historis, dan *hyperparameter tuning* merupakan strategi yang efektif dan dapat direplikasi pada konteks prediksi penjualan lainnya [8], [13].

Dengan demikian, hasil pembahasan ini memperlihatkan bahwa proses pemodelan prediksi penjualan bukan sekadar memilih algoritma terbaik, melainkan merupakan rangkaian tahapan yang saling terkait. Setiap tahap, mulai dari pengolahan data hingga optimasi model, memiliki peran krusial dalam menentukan keberhasilan akhir sistem prediksi. Pendekatan yang digunakan dalam penelitian ini diharapkan dapat menjadi referensi metodologis bagi penelitian selanjutnya maupun implementasi praktis dalam pengembangan sistem prediksi penjualan berbasis *machine learning*.

IV. KESIMPULAN DAN SARAN

Penelitian ini bertujuan untuk membangun model prediksi penjualan pakan sapi MAKO berbasis data deret waktu (*time series*) dengan memanfaatkan pendekatan *machine learning*. Berdasarkan hasil penelitian dan pembahasan yang telah dilakukan, dapat disimpulkan bahwa proses pemodelan prediksi penjualan sangat dipengaruhi oleh pemilihan skala waktu data, strategi rekayasa fitur (*feature engineering*), serta optimasi parameter model. Pemodelan awal menggunakan algoritma *Random Forest Regressor* dengan fitur waktu dasar terbukti tidak mampu mempelajari pola penjualan secara efektif, yang ditunjukkan oleh nilai *R-squared* sebesar 0,00 serta kesalahan prediksi yang sangat tinggi. Kondisi ini menegaskan bahwa data penjualan tidak dapat diperlakukan sebagai data tabular biasa tanpa mempertimbangkan ketergantungan temporal antarperiode.

Peralihan pendekatan dengan mengagregasi data ke skala mingguan serta menambahkan fitur historis berupa *lagged sales* dan *moving average* menjadi langkah penting dalam meningkatkan kualitas representasi data. Pendekatan ini memungkinkan model untuk menangkap tren, musiman, dan momentum penjualan secara lebih jelas. Penggunaan algoritma *Extreme Gradient Boosting (XGBoost)* sebagai model lanjutan memberikan fleksibilitas yang lebih tinggi dalam menangani hubungan nonlinier dan kompleksitas fitur. Namun, hasil pemodelan awal *XGBoost* menunjukkan bahwa algoritma yang kuat sekalipun tidak akan

menghasilkan performa optimal tanpa konfigurasi parameter yang sesuai.

Proses *hyperparameter tuning* menggunakan *GridSearchCV* dengan pendekatan *TimeSeriesSplit* terbukti menjadi faktor penentu keberhasilan model. Melalui proses optimasi ini, performa model meningkat secara signifikan, ditandai dengan lonjakan nilai *R-squared* hingga 0,88 dan penurunan nilai *MAPE* menjadi 6,60%. Hasil tersebut menunjukkan bahwa model mampu menjelaskan sebagian besar variasi penjualan mingguan dan menghasilkan prediksi yang akurat serta stabil. Dengan demikian, penelitian ini memvalidasi bahwa kombinasi rekayasa fitur temporal yang relevan dan optimasi model yang cermat merupakan kunci utama dalam membangun sistem prediksi penjualan yang efektif dan andal, khususnya pada konteks UMKM pakan ternak.

Berdasarkan hasil penelitian ini, beberapa saran dapat diajukan untuk pengembangan penelitian dan implementasi selanjutnya. Pertama, penelitian berikutnya dapat mempertimbangkan penambahan variabel eksternal, seperti faktor cuaca, harga bahan baku, atau kondisi ekonomi peternak, untuk memperkaya informasi yang digunakan dalam pemodelan. Kedua, eksplorasi algoritma lain, seperti *Long Short-Term Memory (LSTM)* atau model hibrida yang mengombinasikan metode statistik dan *machine learning*, dapat dilakukan untuk membandingkan performa pada karakteristik data yang berbeda. Ketiga, implementasi model dalam bentuk sistem pendukung keputusan berbasis aplikasi dapat dikembangkan agar hasil prediksi dapat dimanfaatkan secara langsung oleh pelaku usaha dalam perencanaan produksi dan pengelolaan persediaan. Dengan pengembangan tersebut, model prediksi penjualan diharapkan tidak hanya bernilai akademik, tetapi juga memberikan manfaat praktis yang berkelanjutan bagi usaha pakan sapi MAKO.

V. REFERENCES

- [1] F. Sesilia, V. H. Pranatawijaya, And R. Priskila, "Machine Learning Untuk Memprediksi Jumlah Penjualan, Stok Dan Jumlah Tanam Hasil Pertanian Hidroponik," *Konstelasi Konvergensi Teknol. Dan Sist. Inf.*, Vol. 4, No. 1, Pp. 222–233, 2024.
- [2] M. Al Husaini, A. Hermansyah, V. Purwayoga, H. H. Lukmana, And D. Ramadhan, "Aplikasi Cerdas Berbasis Website Prediksi Harga Emas Dengan Implementasi Algoritma Smoothing Time Series Forecasting," *Data Sci. Indones.*, Vol. 2, No. 2, Pp. 30–43, 2022.
- [3] A. Avinash, A. Widjaja, And O. Karnalim, "Analisis Perbandingan Algoritma Machine Learning Untuk Forecasting Persediaan Produk Barang Pokok," *J. Tek. Inform. Dan Sist. Inf.*, Vol. 10, No. 2, Pp. 361–378, 2024.
- [4] M. C. Harijanto, A. Pinandito, And N. H. Wardani, "Perbandingan Metode Forecasting Arima, Lstm, Dan Prophet Dalam Prediksi Penjualan Produk," *J. Pengemb. Teknol. Inf. Dan Ilmu Komput.*, Vol. 10, No. 01, 2026.
- [5] R. A. Renaldi, M. R. R. Razak, H. Haslindah, And R. Yakub, "Analisis Penggunaan Machine Learning Terhadap Prediksi Jumlah Nasabah Pada Produk Amanah Di Pt. Pegadaian Cps Pangkajene," *J. Maneksi (Management Ekon. Dan Akuntansi)*, Vol. 15, No. 1, Pp. 291–300, 2026.

- [6] K. Hidayat, W. Witanti, And E. Ramadhan, "Analisis Tren Dan Prediksi Penjualan Restoran Menggunakan Model Time Series Prophet," *Metik J. (Akreditasi Sinta 3)*, Vol. 9, No. 2, Pp. 457–467, 2025.
- [7] S. Y. Nailendra, W. Witanti, And G. Abdillah, "Optimasi Prediksi Penjualan Retail Online Menggunakan Lightgbm Dan Hyperparameter Tuning," *J. Algoritma*, Vol. 22, No. 2, Pp. 1931–1942, 2025.
- [8] M. R. Utami And M. I. P. Nasution, "Analisis Literatur Prediksi Tren Penjualan E-Commerce Berbasis Data Time-Series: Metode Statistik & Machine Learning," *J. Ilm. Penelit. Mhs.*, Vol. 3, No. 2, Pp. 331–339, 2025.
- [9] G. C. Sunaryo *Et Al.*, "Implementasi Prediksi Stok Barang Menggunakan Algoritma Support Vector Regression (Svr) Pada Marketplace Umkm Berbasis Microservices," *Informatics Comput. Eng. J.*, Vol. 6, No. 1, Pp. 16–25, 2026.
- [10] D. E. Griffin, K. D. K. A. Wardani, And A. A. N. E. S. Gorda, "Optimalisasi Inventaris Umkm Di Denpasar Melalui Penerapan Sistem Rekomendasi Pemesanan Berbasis Machine Learning," *J. Pengabd. Untukmu Negeri*, Vol. 9, No. 3, Pp. 504–511, 2025.
- [11] A. H. Prayoga And F. A. Alijoyo, "Analisis Prediksi Pola Penjualan Pada Kantin Sehat Universitas Majalengka Menggunakan Data Mining Metode Time Series Analysis Dan Algoritma Sarima," *Informatics Digit. Expert*, Vol. 6, No. 2, Pp. 117–123, 2024.
- [12] M. Y. Basyar, M. A. M. Hayat, And F. I. Rahman, "Prediksi Penjualan Obat Menggunakan Model Lstm Dan Analisis Time Series Pada Data Transaksi Pasien Bpjs," *Mechatronics J. Prof. Entrep.*, Vol. 7, No. 2, 2025.
- [13] F. Riza, "Analisis Dan Prediksi Data Penjualan Menggunakan Machine Learning Dengan Pendekatan Ilmu Data," *Data Sci. Indones.*, Vol. 1, No. 2, Pp. 62–68, 2021.
- [14] R. Rahmat And V. Tundjungsari, "Rancang Bangun Sistem Inventori Berbasis Web Dengan Prediksi Penjualan Menggunakan Time Series Forecasting," *J. Coscitech (Computer Sci. Inf. Technol.)*, Vol. 6, No. 3, Pp. 364–372, 2025.
- [15] R. B. R. Putra And H. Hendry, "Multivariate Time Series Forecasting Pada Penjualan Barang Retail Dengan Recurrent Neural Network," *Inovtek Polbeng-Seri Inform.*, Vol. 7, No. 1, Pp. 71–82, 2022.
- [16] A. Yuliyanto, "Penerapan Teknik Analisis Data Untuk Prediksi Penjualan Exploratory Data Analysis (Eda)," *Jimu J. Ilm. Multidisipliner*, Vol. 2, No. 03, Pp. 922–929, 2024.
- [17] A. Nursikuwagus, R. Munir, M. L. Khodra, And D. A. Dewi, "Model Semantic Attention (Sematt) With Hybrid Learning Separable Neural Network And Long Short-Term Memory To Generate Caption," *Ieee Access*, 2024.
- [18] R. Sidik, M. Fitriawati, S. Mauluddin, And A. Nursikuwagus, "Model Penerapan Algoritma Ant Colony Optimization (Aco) Untuk Optimasi Sistem Informasi Penjadwalan Kuliah," *J. Teknol. Dan Inf.*, Vol. 8, No. 2, Pp. 120–132, 2018.
- [19] S. Mauluddin, I. Ikbali, And A. Nursikuwagus, "Optimasi Aplikasi Penjadwalan Kuliah Menggunakan Algoritma Genetik," *J. Resti (Rekayasa Sist. Dan Teknol. Informasi)*, Vol. 2, No. 3, Pp. 792–799, 2018.
- [20] A. Nursikuwagus, "E-Health As A Service Software Of Medical System In Uml Modeling," 2020.
- [21] I. Djamaludin And A. Nursikuwagus, "Analisis Pola Pembelian Konsumen Pada Transaksi Penjualan Menggunakan Algoritma Apriori," *J. Simetris*, Vol. 8, No. 11, Pp. 671–678, 2017.
- [22] A. R. Putri, N. A. Santoso, And B. A. Santoso, "Implementasi Algoritma Regresi Linier Dan Arima Untuk Prediksi Harga Emas," *Riggs J. Artif. Intell. Digit. Bus.*, Vol. 4, No. 3, Pp. 5194–5200, 2025.
- [23] P. D. Kurniawan, H. D. Surjono, And H. Jati, "Pengembangan Model Hybrid Arima-Machine Learning Untuk Prediksi Harga Saham Bca," *J. Teknol. Inf. Dan Ilmu Komput.*, Vol. 12, No. 6, Pp. 1425–1432, 2025.
- [24] D. S. Manik And N. Panjaitan, "Literatur Review: Penggunaan Algoritma Machine Learning Untuk Optimalisasi Rantai Pasokan," In *Talenta Conference Series: Energy And Engineering (Ee)*, 2025, Pp. 1038–1047.
- [25] N. Sunendar, H. P. Putro, And R. Hesnananda, "Prediksi Penjualan Aerosol Menggunakan Algoritma Arima, Lstm Dan Gru," *Insologi J. Sains Dan Teknol.*, Vol. 4, No. 1, Pp. 113–126, 2025.
- [26] A. U. Swardana, F. E. Nastiti, And S. Sumarlinda, "Sistem Prediksi Penjualan Obat Di Pt. Anugerah Pharmindo Lestari Menggunakan Metode Lstm," In *Prosiding Seminar Nasional Teknologi Informasi Dan Bisnis*, 2025, Pp. 70–77.
- [27] M. Rizki, D. Priyanto, G. H. Martono, N. Sulistianingsih, And M. Syahrir, "Perbandingan Algoritma Sarima Dan Prophet Untuk Peramalan Trend Penjualan Voucher Game Online," *J. Minfo Polgan*, Vol. 14, No. 2, Pp. 1587–1598, 2025.
- [28] L. P. Nasyuli, I. Lubis, And A. M. Elhanafi, "Penerapan Model Machine Learning Algoritma Gradient Boosting Dan Linear Regression Melakukan Prediksi Harga Kendaraan Bekas," *J. Ilmu Komput. Dan Sist. Inf.*, Vol. 2, No. 2, Pp. 183–194, 2023.
- [29] G. Tamami And M. Arifin, "Penggunaan Lstm Dalam Membangun Prediksi Penjualan Untuk Aplikasi Laptop Lens," *J. Fasikom*, Vol. 14, No. 2, Pp. 301–308, 2024.
- [30] H. Wijaya, D. P. Hostiadi, And E. Triandini, "Meningkatkan Prediksi Penjualan Retail Xyz Dengan Teknik Optimasi Random Search Pada Model Xgboost," In *Seminar Hasil Penelitian Informatika Dan Komputer (Spinter)| Institut Teknologi Dan Bisnis Stikom Bali*, 2024, Pp. 829–833.
- [31] Y. M. Nurak, S. W. Iriananda, And F. Marisa, "Prediksi Penjualan Warung Kopi Oi Menggunakan Metode Random Forest Dan Xgboost," *Jati (Jurnal Mhs. Tek. Inform.)*, Vol. 9,

No. 4, Pp. 5796–5802, 2025.

- [32] F. Ali Sofi, “Optimasi Prediksi Penjualan Produk Fashion Di Tiktokshop Menggunakan Xgboost Dan Bayesian Optimization,” 2025, *Universitas Pembangunan Nasional" Veteran" Jawa Timur*.